

Curs d'especialització: **Intel·ligència Artificial i Big Data**
Família Professional: **Informàtica i Comunicacions**
Grau: **Superior**
Durada: **600 hores en un curs de 30 setmanes**

Mòdul 5071 – Models d'intel·ligència artificial



Xavi Blanes – 2026
ies blasco ibáñez Cullera

Índex

Tema 1: Sistemes d'Intel·ligència Artificial

Tema 2: Utilització de Models d'Intel·ligència Artificial


Tema 3: Processament del Llenguatge Natural (PLN)

Tema 4: Sistemes Robotitzats

Tema 5: Sistemes Experts

Tema 6: Principis Legals i Ètics de la IA

Tema 1: Sistemes d'Intel·ligència Artificial



1. Fonaments dels sistemes intel·ligents
2. Sistemes intel·ligents: Camps d'aplicació
3. Tècniques de la Intel·ligència Artificial
4. Noves formes d'interacció

1. Fonaments dels sistemes intel·ligents

Els sistemes intel·ligents són entitats artificials capaces de percebre el seu entorn, processar informació, raonar sobre ella i prendre decisions per a assolir objectius específics. Per a comprendre com es dissenyen actualment, cal analitzar-ne les definicions fonamentals, els mètodes històrics d'avaluació, el paradigma de l'agent racional i l'evolució tecnològica que ha viscut aquesta disciplina.

1.1 Definició de Intel·ligència Artificial (IA)

La Intel·ligència Artificial és una branca de la ciència de la computació que es dedica a la creació de sistemes capaços de realitzar tasques que, si foren fetes per humans, requeririen intel·ligència.

Altra cosa a tenir en compte es la classificació. La matriu de Russell i Norvig és una manera de classificar els diferents tipus d'agents d'intel·ligència artificial segons què fan i com prenen decisions. Apareix en el llibre Artificial Intelligence: A Modern Approach, de Stuart Russell i Peter Norvig.


Russell i Norvig classifiquen els agents en **quatre grans tipus**:

Tipus d'agent	Com decideix?	Exemple
Agent reflex simple	Reacciona a la percepció actual	Termòstat
Agent reflex basat en models	Manté informació sobre l'estat del món	Robot aspirador
Agent basat en objectius	Tria accions que permeten aconseguir un objectiu	GPS
Agent basat en utilitat	Tria l'acció que maximitza la utilitat	Cotxe autònom

1.2 El Test de Turing

Proposat per Alan Turing l'any 1950 en el seu cèlebre article "Computing Machinery and Intelligence", aquest test va canviar la pregunta filosòfica "Poden pensar les màquines?" per una pregunta de caràcter operacional: "Poden les màquines comportar-se de manera intel·ligent?".

El Joc de la Imitació. El test es basa en un joc on intervien tres elements aïllats en habitacions diferents: un interrogador humà, un candidat humà i la màquina (IA). L'interrogador formula preguntes en text lliure. Si passat un temps determinat (normalment 5 minuts de conversa) l'interrogador no pot distingir amb certesa qui és l'humà i qui és la màquina, es considera que la màquina ha passat el test.




Capacitats requerides per a superar el test. Perquè un ordinador pugui superar el Test de Turing clàssic, necessita integrar les següents subàrees de la IA:

- Processament del Llenguatge Natural (PLN): Per a comunicar-se amb èxit en una llengua humana (com el català o l'anglès).
- Representació del Coneixement: Per a emmagatzemar la informació que rep o sap abans de la sessió.
- Raonament Automàtic: Per a utilitzar la informació guardada, respondre preguntes i extraure conclusions.
- Aprenentatge Automàtic (Machine Learning): Per a adaptar-se a noves circumstàncies i detectar patrons.

Nota: Si el test inclou interacció física (Test de Turing Total), també es requereix Visió per Computador (per a percebre objectes) i Robòtica (per a moure's i manipular-los).

1.3 Racionalitat de l'Agent

El paradigma modern de la IA es basa en la noció d'agent racional. Un agent és qualsevol entitat que pugui percebre el seu entorn per mitjà de sensors i actuar en aquest entorn mitjançant actuadors.



Què és ser "Racional"? Un agent és racional si actua de manera que maximitza el valor esperat d'una mesura de rendiment, basant-se en:

- La seqüència de percepcions que ha rebut fins al moment.
- El coneixement previ que té sobre l'entorn.

La racionalitat no implica omnisciència (saber-ho tot), sinó fer el correcte en funció de la informació disponible per a optimitzar el resultat final.

Descripció d'entorns: L'estructura PEAS

Per a dissenyar un agent racional, primer cal definir el seu acrònim PEAS (en anglès: Performance, Environment, Actuators, Sensors):

P (Rendiment / Performance): El criteri numèric o mètrica que mesura l'èxit de l'agent.

E (Entorn / Environment): El món, físic o virtual, on opera l'agent.

A (Actuadors / Actuators): Els mecanismes que té l'agent per a modificar l'entorn.

S (Sensors / Sensors): Els dispositius que capturen dades de l'entorn cap a l'agent.

Exemple de PEAS per a un vehicle autònom:

Rendiment: Arribar a la destinació de forma segura, minimitzar el consum de combustible, complir les lleis de trànsit, minimitzar el temps de viatge.

Entorn: Els carrers i carreteres, el trànsit, els vianants, la pluja o el clima.

Actuadors: Volant, accelerador, fre, intermitents, clàxon.

Sensors: Càmeres RGB, LiDAR, radars, GPS, velocímetre.

1.4 Història de l'evolució:

De la IA Simbòlica al Deep Learning

L'evolució de la IA s'ha caracteritzat per l'alternança entre èpoques de gran optimisme i finançament, i períodes de desil·lusió coneguts com els "Iverns de la IA" (AI Winters).

Èpoques:

1. Naixement de la IA i l'optimisme inicial (1943–1969) 1943: McCulloch i Pitts proposen el primer model de neurona artificial (fita fundacional de la computació neuronal).

1956: Se celebra la Conferència de Dartmouth, organitzada per John McCarthy, Marvin Minsky, Nathaniel Rochester i Claude Shannon. És aquí on es bateja oficialment la disciplina com "Artificial Intelligence".

IA Simbòlica (Good Old-Fashioned AI - GOFAI): Les primeres dècades es van centrar en la manipulació de símbols lògics. Es pensava que la intel·ligència equivalia a resoldre problemes de lògica formal i teoremes matemàtics. Els sistemes es programaven amb regles explícites escrites per humans (codificació dura).

2. El primer ivern de la IA (1970–1980). Els investigadors pensaren que els algorismes que funcionaven en "móns de joguet" no podien escalar cap a problemes del món real a causa de l'explosió combinatòria (complexitat computacional).

1969: Minsky i Papert publiquen el llibre Perceptrons, on demostren matemàticament que una xarxa neuronal d'una sola capa no pot resoldre funcions no lineals simples com la comporta lògica XOR.

El finançament públic es va reduir dràsticament.

3. L'era dels Sistemes Experts (1980–1987). La IA torna a renéixer gràcies a l'enfocament comercial dels Sistemes Experts (com MYCIN o XCON). En lloc d'intentar crear una intel·ligència general, es van dissenyar aplicacions enfocades a dominis molt concrets basats en milers de regles de tipus if .. else.

A mitjans dels anys 80, apareix el segon ivern de la IA perquè aquests sistemes eren molt cars de mantenir, rígids davant canvis de context i no sabien gestionar situacions fora de la seua base de coneixement de regles.

4. L'arribada del Machine Learning (1990–2010). Es produeix un canvi de paradigma radical: en lloc de donar-li les regles a la màquina, li donem dades perquè la màquina aprenga les regles per ella mateixa.

Gràcies a l'estadística computacional i a l'augment del maquinari, guanyen popularitat algorismes com les Màquines de Vectors de Suport (SVM), els Arbres de Decisió i els models de Regressió.

1997: El superordinador Deep Blue d'IBM guanya el campió mundial d'escacs Garri Kaspàrov, demostrant el poder de la força bruta de càlcul i les funcions d'avaluació.

5. L'explosió del Deep Learning (2012–Present). Què ha permés aquesta revolució? La confluència de tres factors: la disponibilitat massiva de dades (Big Data), l'ús de targetes gràfiques (GPUs) per al càlcul en paral·lel, i les millores algorísmiques en xarxes neuronals profundes.

2012: La xarxa neuronal AlexNet guanya la competició de visió per computador ImageNet

per un marge aclaparador, iniciant el boom del Deep Learning. 2016: AlphaGo (de Google DeepMind) guanya a Lee Sedol, campió mundial del complex joc del Go, utilitzant aprenentatge per reforç profund.

Models de Llenguatge Generals: A partir de l'arquitectura Transformer (2017), la IA evoluciona cap a l'era actual de la IA Generativa i els grans models de llenguatge (LLMs), capaços de realitzar raonaments complexos multimodals.

2. Sistemes intel·ligents: Camps d'aplicació

Els sistemes intel·ligents han deixat de ser objecte d'estudi exclusiu dels laboratoris per a convertir-se en un motor de transformació transversal de l'economia i la societat. L'èxit actual de la intel·ligència artificial està en la seua capacitat per a resoldre problemes complexos en sectors clau.

2.1 Visió per Computador (Computer Vision)

La visió per computador és la disciplina que permet a les màquines extraure, processar i comprendre informació visual a partir d'imatges del món real, imatges mèdiques o vídeos.

- **Detecció i classificació d'objectes:** Identificació i localització precisa d'elements dins d'una imatge. S'utilitza en el control de qualitat industrial per a trobar peces defectuoses en cadenes de muntatge a gran velocitat.
- **Reconeixement facial:** Identificació d'identitats digitals a partir de trets biomètrics. S'aplica diàriament en el desbloqueig de telèfons mòbils, el control d'accessos de seguretat o el marcatge automàtic de fotografies.
- **Segmentació d'imatges:** Divisió d'una imatge en píxels corresponents a diferents categories. És vital en la cartografia per satèl·lit per a detectar de forma automàtica zones desforestades, extensions urbanes o canvis en l'ús del sòl.

2.2 Anàlisi de Dades (Data Analytics)

L'anàlisi de dades mitjançant IA combina tècniques d'estadística avançada i aprenentatge automàtic per a descobrir patrons ocults, tendències i relacions en volums massius d'informació (Big Data).

- **Anàlisi Predictiva:** Predicció de comportaments futurs basant-se en dades històriques. Les plataformes de comerç electrònic o de contingut multimèdia (com Netflix o Amazon) l'utilitzen per a dissenyar sistemes de recomanació hiperpersonalitzats que retenen l'usuari.
- **Anàlisi de text i mineria d'opinions:** Processament de ressenyes, comentaris a xarxes socials o enquestes per a mesurar la satisfacció del client. Permet a les

empreses reaccionar en temps real davant d'una crisi de reputació de marca.

- Segmentació de clients (Clustering): Agrupació automàtica d'usuaris amb característiques o patrons de compra similars. Això optimitza les campanyes de màrqueting digital i redueix el cost de captació.

2.3 Salut i Biomedicina

L'aplicació de la IA en la salut està transformant la pràctica mèdica cap a un model més precís, predictiu i personalitzat.

- Diagnòstic per imatge: Models de Deep Learning (com les xarxes neuronals convolucionals) ajuden els radiòlegs a detectar tumors microscòpics, fractures o malalties de la retina en radiografies, ressonàncies magnètiques i TACs amb una precisió equiparable o superior a la humana.
- Descobriments de fàrmacs: Els algorismes d'IA simulen milers de milions de combinacions químiques en qüestió de dies. Plataformes com AlphaFold prediuen l'estructura tridimensional de les proteïnes, reduint els anys de recerca de nous medicaments a pocs mesos.
- Medicina personalitzada: Creació de tractaments a mida analitzant de forma simultània l'historial clínic del pacient, el seu estil de vida i les seues dades genòmiques.

2.4 Finances

El sector financer és un dels entorns digitals més madurs, on la velocitat de decisió i la precisió numèrica són crítiques.

- Detecció del frau en temps real: Anàlisi de milions de transaccions bancàries per segon. Els sistemes intel·ligents bloquegen targetes de crèdit o operacions instantàniament si detecten un patró de despesa anòmal o geolocalitzacions impossibles de l'usuari.
- Trading algorísmic (Trading d'alta freqüència): Execució automàtica d'ordres de compra i venda d'accions o divises en borsa en mil·lisegons. Aquests agents reaccionen instantàniament a notícies d'última hora, esdeveniments geopolítics o tendències microeconòmiques.
- Avaluació de riscos crediticis (Credit Scoring): Automatització de l'anàlisi de viabilitat per a la concessió de préstecs o hipoteques. El sistema avalua el risc d'impagament d'un perfil en segons creuant dades bancàries clàssiques amb patrons de comportament financer.

2.5 Automoció i Transport

La convergència entre mecànica, sensors d'última generació i models d'IA està redefinint la mobilitat urbana i logística.

- **Vehicles Autònoms:** Cotxes, camions i drons utilitzen sistemes de visió i aprenentatge per reforç per a prendre decisions de conducció crítiques a la carretera. El sistema fusiona dades de càmeres, LiDAR i radars per a mantenir-se al carril, respectar senyals i evitar col·lisions.
- **Manteniment Predictiu de flotes:** Els sensors IoT (Internet of Things) instal·lats en trens, avions o flotes de camions envien dades de vibració, temperatura o pressió a la IA. L'algorisme avisa de quina peça fallarà abans que es produísca l'avaria, evitant parades encobertes.
- **Optimització de rutes logístiques:** Planificació dinàmica del repartiment de mercaderies tenint en compte el trànsit en temps real, les finestres horàries de lliurament i la meteorologia, reduint els costos de combustible i els terminis.

2.6 Ciberseguretat

En un entorn on les amenaces informàtiques evolucionen de forma diària, les defenses tradicionals basades en llistes de virus coneguts ja no són suficients.

- **Anàlisi del comportament i detecció d'anomalies:** La IA aprén el patró d'activitat normal de la xarxa d'una empresa (horaris d'accés dels treballadors, volum de descàrrega de dades, servidors utilitzats). Si un usuari comença a descarregar milers de fitxers confidencials a les tres de la matinada, el sistema aïlla l'equip de forma preventiva.
- **Defensa contra atacs de Dia Zero (Zero-Day):** Reconeixement de codi maliciós mai vist abans analitzant la seua estructura o la seua intencionalitat en lloc del seu nom o signatura digital.
- **Automatització de respostes davant d'incidents:** Bloqueig automatitzat de ports, tancament de sessions vulnerades o mitigació d'atacs de denegació de servei (DDoS) abans que els enginyers humans puguin avaluar manualment el problema.

3. Tècniques de la Intel·ligència Artificial:

Per a implementar les aplicacions analitzades en el punt anterior, la IA es basa en un conjunt de tècniques i enfocaments matemàtics i computacionals. Aquestes tècniques es poden dividir en dos grans mons:

- la IA basada en la cerca i l'optimització (més clàssica i estructurada) i

- la IA basada en les dades (l'aprenentatge automàtic i les xarxes neuronals).

3.1 Algorismes de Cerca i Optimització

Quan un problema es pot modelar completament mitjançant regles, estats i accions, utilitzem algorismes de cerca per a trobar la seqüència òptima de passos que ens porta des d'una situació inicial fins a un objectiu.

1. Cerca no informada (Cega). No disposen de cap pista sobre quina direcció és millor per a arribar a l'objectiu; exploren l'espai d'estats de manera sistemàtica.

- Cerca en amplada (BFS - Breadth-First Search): Explora primer tots els nodes d'un nivell abans de passar al següent. Garanteix trobar el camí més curt si totes les accions tenen el mateix cost.
- Cerca en profunditat (DFS - Depth-First Search): Explora un camí fins a la màxima profunditat possible abans de fer marxa enrere (backtracking). Consumeix menys memòria que BFS, però pot no trobar la solució més ràpida.

2. Cerca informada (Heurística). Utilitzen coneixement específic del problema per a estimar quins camins tenen més probabilitat d'èxit, reduint dràsticament el temps de càlcul. L'algorisme A* és l'algorisme de cerca més conegut.


Algorisme A*: Utilitza una funció d'avaluació $f(n) = g(n) + h(n)$, on $g(n)$ és el cost real per a arribar al node actual i $h(n)$ és una estimació (heurística) del cost que queda fins a l'objectiu. S'usa de forma intensiva en videojocs per al moviment de personatges (pathfinding) i en sistemes de navegació GPS.

3. Algorismes d'Optimització i Metaheurístiques. Quan l'espai de solucions és tan immens que és impossible explorar-lo sencer, es busquen solucions "prou bones" o òptims locals. Destacarem els més importants: Algorismes Genètics.

Algorismes Genètics (GA): Inspirats en l'evolució natural. Es crea una "població" de solucions potencials que es creuen, muten i se seleccionen al llarg de generacions segons la seua adaptació (funció de fitness).

3.2 Aprenentatge Automàtic (Machine Learning)

L'Aprenentatge Automàtic és el subcamp de la IA que dona als ordinadors la capacitat d'aprendre sense ser programats de manera explícita. Consisteix a dissenyar algorismes que identifiquen patrons en les dades per a fer prediccions o prendre decisions. Es divideix en tres grans paradigmes:



1. Aprenentatge Supervisat. L'algorisme s'entrena amb un conjunt de dades on la resposta correcta ja és coneguda (dades etiquetades).

Classificació: La variable a predir és discreta o categòrica (Ex: Aquest correu és "Spam" o "No Spam"?, Aquesta imatge és un gos o un gat?).

Algorismes clàssics: Arbres de Decisió, K-Nearest Neighbors (KNN), Naive Bayes o Màquines de Vectors de Suport (SVM).

Regressió: La variable a predir és numèrica i contínua (Ex: Quin serà el preu d'un pis l'any vinent?, Quants productes es vendran demà?).

Algorismes clàssics: Regressió Lineal, Regressió Polinòmica.

2. Aprenentatge No Supervisat. L'algorisme rep dades sense cap etiqueta ni resposta correcta. El seu objectiu és trobar de manera autònoma l'estructura o agrupacions ocultes en les dades.

Clustering (Agrupament): Divideix les dades en grups on els elements interns s'assemblen molt entre ells i es diferencien dels altres grups (Ex: Algorisme K-Means per a segmentar clients de forma automàtica).


Reducció de la Dimensionalitat: Simplifica dades molt complexes eliminant variables redundants sense perdre la informació essencial (Ex: PCA - Principal Component Analysis).

3. Aprenentatge per Reforç. L'algorisme (anomenat agent) aprèn a interactuar amb el seu entorn mitjançant el mètode de prova i error. No rep dades de mostra, sinó que fa accions i rep recompenses positives (si ho fa bé) o penalitzacions (si ho fa malament). L'objectiu és maximitzar la recompensa total a llarg termini. És la tècnica utilitzada per a ensenyar a jugar a videojocs o per al control de braços robòtics.

3.3 Xarxes Neuronals (Neural Networks) i Deep Learning

Les Xarxes Neuronals Artificials (ANN) són un subconjunt del Machine Learning inspirat vagament en l'estructura biològica del cervell humà. Quan aquestes xarxes tenen moltes capes interconnectades, parlem de Deep Learning (Aprentatge Profund).

La Neurona Artificial (Perceptron). És la unitat bàsica de processament. Rep un conjunt d'entrades ($x_1, x_2, \dots$), les multiplica per uns pesos matemàtics ($w_1, w_2, \dots$), suma un biaix (b) i passa el resultat per una funció d'activació (com ReLU o Sigmoid) que introdueix la no-linealitat per a decidir si la neurona s'ha d'activar o no.



Arquitectures de Xarxes Neuronals més importants: L'Aprentatge Profund ha triomfat perquè dissenya estructures adaptades al tipus de dada que ha de processar:

- Xarxes Neuronals Convolucionals (CNN): Dissenyades específicament per a processar imatges o dades en graella. Utilitzen "filtres" (convolucions) que detecten primer línies i vores, després formes simples i, finalment, objectes complexos. Són la base de la Visió per Computador.
- Xarxes Neuronals Recurrents (RNN) i LSTM: Dissenyades per a dades seqüencials o temporals, on l'ordre de la informació importa (text escrit, àudio o sèries històriques de borsa). Tenen "memòria" del que ha passat en els passos anteriors.
- Transformers: L'arquitectura moderna més potent (presentada en 2017). Substitueix les RNN gràcies al mecanisme d'atenció. Permet processar textos sencers de manera simultània (en paral·lel) en lloc de paraula per paraula. Són la tecnologia core darrere de tots els models de llenguatge actuals com els GPT, Claude o Llama.

4. Noves formes d'interacció

L'evolució de la Intel·ligència Artificial no només ha canviat la manera en què les màquines processen la informació, sinó també la forma en què els humans ens relacionem amb elles.

Hem passat de les interfícies de línia de comandes (CLI) i les interfícies gràfiques d'usuari (GUI) basades en ratolí i pantalla, a interfícies naturals d'usuari (NUI), on la veu, els gestos, el context i les emocions configuren una interacció molt més orgànica.

4.1 Interfícies d'Usuari de Veu (VUI - Voice User Interfaces)

Les VUI permeten a l'usuari interactuar amb un sistema mitjançant la parla. Aquesta tecnologia requereix la integració coordinada de tres components basats en IA:

- **Reconeixement Automàtic de la Parla (ASR - Automatic Speech Recognition):** Transforma l'ona d'àudio de la veu de l'usuari en text escrit.
- **Comprensió del Llenguatge Natural (NLU - Natural Language Understanding):** Analitza el text per a extraure'n la intenció (intent) i les dades clau (entities). Per exemple, de la frase "Abaixa la temperatura a 21 graus", la intenció és `modificar_climatitzacio` i l'entitat és `temperatura: 21`.
- **Síntesi de Text a Parla (TTS - Text-to-Speech):** Converteix la resposta textual del sistema en un fitxer d'àudio amb veu natural i entonació humana. Exemples d'ús clàssics: Assistents virtuals domèstics (Amazon Alexa, Apple Siri), sistemes d'infocentre en vehicles o sistemes de dictat automàtic per a informes mèdics.

4.2 Agents Conversacionals i IA Generativa

Els agents conversacionals han evolucionat des dels sistemes rígids basats en arbres de decisió i regles fins als assistents d'intel·ligència artificial generativa de l'era actual.

- **Chatbots clàssics (Basats en fluxos):** Funcionaven amb paraules clau i oferien botons de resposta tancats. Si l'usuari sortia del guió establert, el sistema fallava.
- **Agents basats en LLMs (Grans Models de Llenguatge):** Són capaços d'entendre el context profund de la conversa, mantenir el fil del diàleg al llarg de múltiples interaccions, gestionar la ironia i respondre de manera completament oberta i natural.
- **Arquitectura RAG (Retrieval-Augmented Generation):** És la tendència industrial actual. Permet connectar un model de llenguatge massiu a una base de dades privada de l'empresa. D'aquesta manera, l'agent conversacional respon les preguntes dels usuaris basant-se en informació real, precisa i actualitzada, evitant les "al·lucinacions".

4.3 Realitat Augmentada Intel·ligent (IA + AR)

La combinació de la Realitat Augmentada (superposició d'elements digitals sobre el món físic) amb la Intel·ligència Artificial permet que els dispositius interactuen amb l'entorn de manera dinàmica en lloc de mostrar informació estàtica.

- **Comprensió de l'espai en temps real:** La IA processa el flux de vídeo del dispositiu (com unes ulleres intel·ligents o un mòbil) mitjançant algorismes de Computer Vision per a reconèixer superfícies, profunditats i objectes concrets (moblari,


parets, màquines).

- Assistència tècnica industrial guiada: Un operari de fàbrica pot mirar un motor complex amb unes ulleres d'AR. La IA identifica el model de la màquina, detecta quina peça està fallant i superposa fletxes en 3D i instruccions animades exactament sobre la vàlvula que s'ha de canviar.
- Traducció i etiquetatge en viu: Dispositius capaços de traduir instantàniament rètols de carrer o menús de restaurants en un text digital integrat en el mateix cartell físic que l'usuari està mirant.

4.4 Reconeixement d'Emocions (Computació Afectiva)


La Computació Afectiva és el camp de la IA que busca dotar els sistemes de la capacitat de reconèixer, interpretar i processar l'estat emocional de l'ésser humà per a adaptar la resposta de la màquina de manera empàtica.

La IA utilitza un enfocament multimodal per a analitzar l'estat emocional:



Visió per computador afectiva: Models que analitzen els canvis geomètrics en els ulls, les celles o la boca (microexpressions basades en el Sistema de Codificació de l'Acció Facial - FACS) per a determinar si l'usuari mostra felicitat, frustració, avorriment o estrès. Aplicacions industrials reals: Automoció: Càmeres instal·lades al tablier del cotxe que detecten signes de fatiga, son o distraccions en les expressions de la cara del conductor i activen alertes sonores. Educació en línia (E-learning): Sistemes que avaluen si els alumnes estan confosos o avorrits davant d'un contingut per a adaptar el ritme de la lliçó de manera automàtica. Atenció al client: Enrutament de trucades de call centers cap a agents humans si la IA detecta un to de veu d'enuig o ràbia en l'usuari.

Tema 2: Utilització de Models d'Intel·ligència Artificial



1. Requisits bàsics d'un sistema de resolució de problemes
2. Automatització de tasques
3. Sistemes de raonament imprecís
4. Sistemes basats en regles

1. Requisits bàsics d'un sistema de resolució de problemes

En la Intel·ligència Artificial clàssica i en el disseny d'agents racionals, la resolució de problemes es concep com un procés de cerca en un espai de possibilitats.

Abans que un algorisme pugui cercar una solució, l'entorn i la situació s'han de formalitzar matemàticament. Aquesta formalització requereix definir de manera precisa quatre elements: l'espai d'estats, l'estat inicial, els objectius (o prova d'objectiu) i els costos de camí.

1.1 Formulació del Problema

La formulació del problema és el procés d'asseure les bases de dades i les regles lloques que permetran a la màquina operar. Consisteix a decidir quins aspectes del món real són rellevants i quins es poden ignorar (abstracció).

Per a formular un problema correctament, un sistema intel·ligent necessita definir cinc components formals:

- L'estat inicial: La situació de sortida en la qual es troba l'agent.
- Les accions disponibles: El conjunt de moviments o decisions vàlides que l'agent pot prendre des d'un estat determinat. Es denota com $Actions(s)$.
- El model de transició: La descripció de què fa cada acció. Retorna l'estat resultant d'aplicar una acció concreta a un estat determinat. Es representa matemàticament com $Result(s, a)$.
- La prova d'objectiu (Goal Test): El criteri que determina si un estat actual és la solució al problema.
- La funció de cost del camí: Una mètrica numèrica que quantifica el cost de moure's d'un estat a un altre.

1.2 Definició de l'Espai d'Estats

L'espai d'estats és el conjunt de tots els estats de l'entorn que es poden aconseguir des de l'estat inicial mitjançant qualsevol seqüència d'accions vàlides.

- Estat: És una configuració o representació instantània de l'entorn. Ha de contenir només la informació necessària per a resoldre el problema.
- Graf de l'espai d'estats: Visualment, l'espai d'estats es representa com un graf on els nodes són els estats i les arestes (o fletxes) són les accions que permeten transitar d'un estat a un altre.

Exemple Clàssic: El trencaclosques del 8 (8-puzzle)

Imagina un tauler de 3x3 amb 8 fitxes numerades de l'1 al 8 i un espai buit.

Estat inicial: Una configuració aleatòria de les fitxes en el tauler (ex: l'espai buit al mig, l'1 a dalt a la esquerra, etc.).

Espai d'estats: Totes les combinacions numèriques de posicions que es poden aconseguir movent les fitxes cap a l'espai buit (en total hi ha $9! / 2 = 181.440$ estats possibles).

Accions: Moure l'espai buit cap a l'Esquerra, Dreta, Dalt o Baix (depenent de la seua posició).

ESTAT INICIAL					ESTAT OBJECTIU			
1	2	3		==>	1	2	3	
4		6			4	5	6	
7	5	8			7	8		

1.3 Definició d'Objectius (Goal Test)

L'objectiu és la meta que l'agent vol assolir. La prova d'objectiu és la funció o mecanisme que utilitza el sistema per a comprovar si ha acabat la seua tasca amb èxit.

Hi ha dos tipus de definicions d'objectius:

Objectiu explícit: El sistema busca un estat únic i perfectament conegut per endavant.

Exemple: En el joc del 8-puzzle, l'estat objectiu és exactament el tauler ordenat de l'1 al 8 d'esquerra a dreta i de dalt a baix.

Objectiu abstracte o per condició: L'agent no coneix la configuració exacta de l'estat final, però coneix les propietats que ha de complir aquest estat.

Exemple en escacs: L'objectiu és aconseguir qualsevol estat del tauler on el rei contrari estiga en situació de "escac i mat".

Hi ha milions d'estats diferents que compleixen aquesta condició.

1.4 Costos de Camí (Path Cost)

No totes les solucions d'un problema són igual de bones. Per a triar la millor seqüència d'accions, introduïm el concepte de cost de camí.

Funció de cost del pas ($c(s, a, s')$): És el cost d'executar l'acció a en l'estat s per a arribar a l'estat s' . El dissenyador de la IA l'assigna en funció de les prioritats del sistema (pot representar temps, diners, consum d'energia, distància o qualsevol altre recurs).

Cost total del camí ($g(n)$): És la suma dels costos de cada pas individual al llarg d'una seqüència d'accions des de l'estat inicial fins a l'estat actual.

Un sistema de resolució de problemes busca una solució òptima, que és aquella seqüència d'accions que ens porta des de l'estat inicial a un estat objectiu amb el menor cost de camí possible.

Exemple d'aplicació GPS (Enrutament de vehicles):

Estat inicial: València.

Objectiu: Barcelona.

Accions: Conduir cap a una ciutat veïna connectada per carretera.

Cost de camí: El temps estimat de viatge o els quilòmetres entre ciutats.

El camí òptim serà la ruta més ràpida (menor cost en temps).

2. Automatització de tasques

L'automatització de tasques en l'àmbit empresarial ha evolucionat des de scripts i macros rígides cap a sistemes dinàmics capaços de prendre decisions basades en el context. Dins d'aquest ecosistema, destaquen l'RPA intel·ligent (o hiperautomatització) i l'automatització de fluxos de treball impulsada per dades (data-driven workflows).

2.1 RPA Intel·ligent (Robotic Process Automation Intel·ligent)

L'RPA clàssic consisteix en programari (conegut com a "robot" o "bot") que emula les accions d'un humà en una interfície digital per a realitzar tasques repetitives. No obstant això, l'RPA Intel·ligent (també anomenat Cognitive Automation o IPA) integra capacitats d'Intel·ligència Artificial i Machine Learning per a gestionar processos que requereixen un cert grau de judici o comprensió de dades no estructurades.

Diferències entre RPA Clàssic i RPA Intel·ligent

Característica	RPA Clàssic	RPA Intel·ligent
Tipus de dades	Només dades altament estructurades (Excel, bases de dades).	Dades no estructurades (PDFs escanejats, correus lliures, àudios).
Lògica de decisió	Basada estrictament en regles fixes (IF/THEN).	Basada en models probabilístics d'aprenentatge automàtic.
Gestió d'excepcions	El bot falla si la interfície canvia un sol píxel.	El bot s'adapta utilitzant visió per computador o comprensió contextual.
Nivell cognitiu	"Fer" (execució de tasques mecàniques).	"Pensar i Fer" (anàlisi de la dada abans de l'acció).


Tecnologies que componen l'RPA Intel·ligent

Perquè un bot d'RPA clàssic esdevinga intel·ligent, s'hi integren mòduls com:

- IDP (Intelligent Document Processing): Utilitza OCR (Reconeixement Òptic de Caràcters) avançat combinat amb PLN per a llegir factures, contractes o albarans escanejats, extraure'n els camps clau (com import total o CIF) de manera autònoma i introduir-los en un ERP (com SAP).
- Visió per Computador superficial: Permet al bot interactuar amb entorns virtualitzats (com Citrix o l'escriptori remot) reconeixent de forma visual on estan els botons o camps de text, encara que el codi intern de l'aplicació estiga ocult.

2.2 Automatització de fluxos de treball basats en dades (Data-Driven Workflows)

Aquest enfocament consisteix a dissenyar processos operatius on l'arribada, el canvi o l'anàlisi de les dades és el que activa (triggers) i dirigeix les accions de forma automàtica, sense intervenció humana directa.



Fases d'un flux de treball basat en dades

- **Ingesta de dades (Ingestion):** Captura en temps real de dades provinents de diferents fonts (APIs, bústies de correu, formularis, dispositius IoT).
- **Orquestració i Processament (Orchestration):** Plataformes especialitzades (com Apache Airflow, Prefect o n8n) gestionen la dependència entre tasques. Un mòdul de Machine Learning processa la dada ingressada per a classificar-la o generar una predicció.

- Acció Automatitzada (Execution): En funció del resultat de la IA, el flux es bifurca instantàniament.

Exemple d'ús en un departament de Suport Tècnic:

Un client envia un correu electrònic de queixa.

El flux de treball s'activa i passa el text per un model d'Anàlisi de Sentiment (PLN).

Si el model detecta que el sentiment és "Molt enfadat", el sistema assigna automàticament el cas com a Prioritat Crítica, l'envia al supervisor directament per un canal de Slack i genera un esborrany de resposta automatitzat demanant disculpes amb dades específiques del problema de l'usuari.

3. Sistemes de raonament imprecís

Els ordinadors tradicionals funcionen amb la lògica booleana o aristotèlica, on una afirmació només pot ser vertadera o falsa ($\{1\}$ o $\{0\}$). No obstant això, el pensament humà i molts problemes del món real operen amb conceptes imprecisos o ambigus (com "fa molta calor", "està prop" o "el motor gira lent").

La lògica borrosa (Fuzzy Logic), desenvolupada per Lotfi A. Zadeh el 1965, proporciona un marc matemàtic per a representar i processar aquesta informació imprecisa.

3.1 Conjunts Difusos i Funcions de Pertinença

En la teoria de conjunts clàssica (crisp), un element pertany o no pertany a un conjunt de forma absoluta. En un conjunt difús, la transició és gradual: un element pot tenir una pertinença parcial al conjunt.

1. Funció de Pertinença (μ) És el nucli del raonament imprecís. És una funció matemàtica que assigna a cada element de l'univers de discurs un grau de pertinença situat en l'interval tancat $[0, 1]$.

Un valor de 0 significa que l'element no pertany en absolut al conjunt.

Un valor d'1 significa que l'element pertany totalment al conjunt.

Qualsevol valor intermedi (ex:0.65) indica una pertinença parcial.


2. Formes de les Funcions de Pertinença Depenent del problema, les funcions se solen dissenyar amb geometries simples per a facilitar el càlcul computacional:

Triangulars: Definides per tres punts de control. Ideals per a valors que tenen un punt

òptim central.

Trapezoïdals: Definides per quatre punts. Útils quan hi ha un rang ample de valors que tenen pertinença màxima (1).

Gaussianes: Basades en la campana de Gauss. Ofereixen transicions molt suaus, ideals per a sistemes de control altament precisos.



3.2 Operacions Fonamentals de la Lògica Borrosa

De la mateixa manera que la lògica booleana té les operacions AND, OR i NOT, la lògica borrosa redefineix aquests operadors per a treballar amb valors decimals entre 0 i 1. Les formes més habituals (definides per Zadeh) són:

Intersecció (Operador AND / T-Norma): Es calcula com el mínim dels graus de pertinença.

$$\mu_{A \cap B}(x) = \min(\mu_A(x), \mu_B(x))$$

Unió (Operador OR / T-Conorma): Es calcula com el màxim dels graus de pertinença.


$$\mu_{A \cup B}(x) = \max(\mu_A(x), \mu_B(x))$$

Negació (Operador NOT / Complement): Es calcula restant a 1 el grau de pertinença actual.

$$\mu_{\neg A}(x) = 1 - \mu_A(x)$$

3.3 Controladors Fuzzies (Sistemes de Control Difús)

Un controlador fuzzy és un sistema que utilitza regles de tipus if .. else per a transformar variables d'entrada reals en accions de control reals, passant per un procés de raonament imprecís. És l'arquitectura més estesa en la indústria per a regular electrodomèstics, motors o processos químics. L'arquitectura d'un controlador fuzzy es compon de quatre fases clau:



1. Fuzzificació (Fuzzification). Consisteix a agafar les dades reals que mesuren els sensors (valors concrets o crisp) i calcular el seu grau de pertinença en els conjunts difusos definits.

Exemple: Si el sensor diu que la temperatura és de 24°C, la fuzzificació determinarà que és 0.3 "Calenta" i 0.7 "Templada".

2. Base de Regles i Motor d'Inferència. El motor combina els graus de pertinença calculats amb una base de coneixement formada per regles lingüístiques descrites per un expert humà.

Exemple de regla: Si la temperatura és Calenta I l'humitat és Alta, LLAVORS la velocitat del ventilador ha de ser Ràpida.

El motor utilitza els operadors borrosos (min o max) per a avaluar la premissa de la regla i "retallar" el conjunt difús d'eixida correlatiu.

3. Defuzzificació (Defuzzification). Com que un actuator físic (un motor, una vàlvula) no pot rebre una ordre abstracta com "velocitat una mica ràpida", cal transformar el conjunt

difús agregat d'eixida en un sol valor real i precís.

Mètode del Centroide (o Centre de Gravat): És el mètode més utilitzat. Calcula el centre geomètric de l'àrea sota la corba de pertinença de leixida resultant. Aquest valor numèric és l'ordre física que s'envia a l'actuador.

Exemples d'aplicació real: Màquines de llavar intel·ligents: Mesuren la brutícia de l'aigua mitjançant un sensor òptic i utilitzen lògica borrosa per a decidir la durada òptima del cicle de llavat i la quantitat de detergent.

Frenada de trens metropolitans (Metro): Garanteix una frenada suau a l'estació regulant la pressió hidràulica segons el pes del comboi i la distància de seguretat, evitant les sotragades de la lògica tradicional.


4. Sistemes basats en regles

Els sistemes basats en regles constitueixen un dels pilars fonamentals de la Intel·ligència Artificial simbòlica (GOFAI). A diferència dels models moderns d'aprenentatge automàtic, que extreuen patrons a partir de dades de forma probabilística, els sistemes basats en regles codifiquen el coneixement humà de forma explícita mitjançant declaracions lògiques de tipus deductiu.

4.1 Arquitectura d'un Motor de Regles

Un motor de regles (o sistema de producció) és el programari dissenyat per a gestionar, avaluar i executar un conjunt de regles sobre una col·lecció de dades coneguda.

L'arquitectura estàndard es divideix en tres components principals:



- Base de Coneixement (Rule Base): Emmagatzema el conjunt de regles de

producció que descriuen el domini. Cada regla té una estructura fixa: SI Premissa / Antecedent LLAVORS Conseqüència / Conseqüent.

- Memòria de Treball (Working Memory): Conté els fets coneguts actualment pel sistema. Són les dades reals de la situació actual o les veritats temporals.
- Motor d'Inferència (Inference Engine): És el cervell del sistema. S'encarrega d'encreuar els fets de la Memòria de Treball amb les regles de la Base de Coneixement per a derivar nous fets o accions a través d'un cicle de tres fases:
 - a) Encreuament de patrons (Pattern Matching): Troba quines regles tenen una premissa que es compleix amb els fets actuals. L'algorisme clàssic més utilitzat per a optimitzar aquesta fase és l'Algorisme Rete.
 - b) Resolució de conflictes: Si diverses regles es compleixen a la vegada, el motor decideix quina d'elles s'executa primer segons criteris de prioritat, especificitat o ordre temporal.
 - c) Execució: S'activa la regla seleccionada, la qual cosa sol afegir, modificar o eliminar fets de la memòria de treball, o realitzar una acció externa.

4.2 Mecanismes de Raonament: Encadenament cap avant (Forward Chaining)

L'encadenament cap avant és un mètode de raonament impulsat per les dades (data-driven). Comença amb els fets disponibles a la memòria de treball i aplica les regles de producció per a extreure conclusions o derivar nous fets de forma successiva fins a assolir un objectiu.

Com funciona?

- El sistema rep un conjunt de fets inicials.
- Cerca totes les regles les premisses de les quals siguin vertaderes segons els fets de la memòria.
- Executa la regla seleccionada i afeg el seu conseqüent com a un nou fet a la memòria.
- Repeteix el procés fins que no es puguin activar més regles o s'arribi a la meta final.

Exemple d'aplicació (Diagnòstic de fallades elèctriques):

- Fets inicials: El dispositiu no s'encén i El pilot de la font d'alimentació està apagat.
- Regla 1: SI El dispositiu no s'encén I El pilot està apagat LLAVORS afeg el fet No arriba corrent elèctric.
- Regla 2: SI No arriba corrent elèctric LLAVORS afeg el fet El fusible podria estar fos.

- Resultat: El sistema dedueix progressivament de forma automàtica la causa de l'avaría partint dels símptomes detectats.

4.3 Mecanismes de Raonament: Encadenament cap arrere (Backward Chaining)

L'encadenament cap arrere és un mètode de raonament impulsat pels objectius (goal-driven). Comença amb una meta o hipòtesi final que es vol demostrar i treballa en sentit invers per a veure si els fets de la memòria de treball donen suport a aquesta conclusió.

Com funciona?

- El sistema selecciona un objectiu (Ex: Està el fusible fos?).
- Cerca regles que tinguin aquest objectiu en el seu conseqüent (la part del LLAVORS).
- Si en troba una, les premisses d'aquesta regla es converteixen en els nous subobjectius que cal demostrar.
- El sistema continua buscant cap enrere fins que tots els subobjectius coincideixen amb fets reals ja coneguts a la memòria de treball. Si algun subobjectiu no es pot demostrar i no hi ha més regles, la hipòtesi es descarta com a falsa.

Exemple d'aplicació (Sistemes de control de crèdit o concessions de visats):

- Objectiu inicial: Demostrar si L'usuari és apte per a la hipoteca.
- Cerca cap enrere: El sistema troba la Regla 3: SI Té feina estable I Està lliure de deutes LLAVORS L'usuari és apte per a la hipoteca.
- Nous subobjectius: Ara el motor intenta comprovar de forma prioritària si Té feina estable. Buscarà a la memòria o preguntarà a la base de dades si existeix aquest fet abans d'avaluar qualsevol altra variable irrellevant.

Comparativa Directa d'Enfocaments

Característica	Encadenament cap avant (<i>Forward</i>)	Encadenament cap arrere (<i>Backward</i>)
Punt de partida	Fets i dades inicials disponibles.	Un objectiu o hipòtesi final.
Direcció del procés	Des de les premisses cap a les conclusions.	Des de les conclusions cap a les premisses.
Enfocament principal	Impulsat per dades (<i>Data-driven</i>).	Impulsat per objectius (<i>Goal-driven</i>).
Cas d'ús ideal	Quan hi ha molts fets inicials i l'objectiu és obert (Ex: planificació, mineria de dades).	When l'objectiu és únic o tancat i cal verificar-lo (Ex: diagnòstic mèdic, auditories).

Tema 3: Processament del Llenguatge Natural (PLN)



1. Processament del llenguatge natural: Potencial i limitacions
 - 1.1 El Potencial del PLN Modern
 - 1.2 Les Limitacions de la IA davant del Llenguatge Humà
 - 1.3 El Salt del Text Escrit a la Comprensió Profunda
2. Aplicaciones del PLN:
 - 2.1 Traductors Automàtics
 - 2.2 Anàlisi de Sentiment (Sentiment Analysis)
 - 2.3 Resum de Texts (Text Summarization)
 - 2.4 Reconeixement de Text (OCR - Optical Character Recognition)
 - 2.5 Grans Models de Llenguatge (LLMs - Large Language Models)

1. Processament del llenguatge natural: Potencial i limitacions

El Processament del Llenguatge Natural (PLN o NLP en anglés) és la disciplina de la Intel·ligència Artificial que s'encarrega d'aconseguir que les màquines computacionals entenguin, interpreten, manipulen i generen llenguatge humà de manera eficaç.

Tot i l'èxit massiu dels models actuals, el llenguatge humà presenta reptes estructurals complexos.


1.1 El Potencial del PLN Modern

L'arribada de les arquitectures basades en Transformers i els Grans Models de Llenguatge (LLMs) ha transformat el PLN de ser un simple processador estadístic de paraules a una eina amb capacitats cognitives avançades:

- Generació de text coherent: Creació de documents complexos, assajos, correus o codi de programació amb una sintaxi perfecta i un estil adaptat a l'usuari.
- Traducció automàtica contextual: Traducció entre centenars d'idiomes superant la traducció literal "paraula per paraula" per a mantindre el significat global de la frase.
- Capacitat de resum i síntesi: Extracció de les idees clau de milers de pàgines de text no estructurat en pocs segons, optimitzant la recerca documental i l'anàlisi de dades empresarials.
- Interfície universal: Conversió del llenguatge natural en el codi d'execució de programari, fent que qualsevol humà puga programar o interactuar amb bases de dades complexes només parlant o escrivint.

1.2 Les Limitacions de la IA davant del Llenguatge Humà

Malgrat la seua fluïdesa sintàctica, els sistemes intel·ligents pateixen de carències fonamentals a l'hora de comprendre la semàntica i la pragmàtica humana. Les seues principals barreres són:



1. L'Ambigüïtat del Llenguatge. El llenguatge humà és intrínsecament ambigu a diferència dels llenguatges de programació. Un sistema de PLN ha de resoldre constants conflictes en diversos nivells:

- Ambigüïtat Lèxica (Polisèmia): Una mateixa paraula canvia de sentit segons la categoria gramatical o el context. Exemple: La paraula "banc" pot ser una entitat financera, un moble per a seure o un conjunt de peixos.
- Ambigüïtat Sintàctica: L'estructura d'una frase permet múltiples interpretacions. Exemple: "Vaig veure un home amb un telescopi". Qui tenia el telescopi? L'home que caminava o jo?

2. La Dependència del Context i el Coneixement del Món. Els humans no ho diem tot explícitament; confiem que el receptor comparteix una gran quantitat de coneixements implícits del món físic i social (sentit comú).

Exemple: "El trofeu no cabia a la maleta de fusta perquè era massa gran". Si preguntem a una IA què era massa gran (el trofeu o la maleta), necessita conèixer les lleis físiques de l'espai tridimensional per a deduir de forma correcta que es refereix al trofeu. Si canviem la frase a "...perquè era massa petita", el subjecte canvia instantàniament a la maleta (Problema d'esquemes de Winograd).

3. L'Ironia i el Sarcasme. L'ironia consisteix a expressar el contrari d'allò que realment es pensa per a fer una burla o una crítica. Com que els models d'IA s'entrenen analitzant la literalitat estadística del text escrit, detectar el sarcasme és un dels majors reptes del PLN actual.

Exemple: Escriure "M'encanta que el tren arribe amb dues hores de retard, és genial" en una ressenya d'atenció al client. Un model simple d'Anàlisi de Sentiment etiquetarà les paraules "encanta" i "genial" com a un sentiment positiu, errant completament en el diagnòstic de la dada.

1.3 El Salt del Text Escrit a la Comprensió Profunda

La comunitat científica actual es divideix en un debat fonamental sobre si la tecnologia vigent realment "entén" o si és només un "lloro estocàstic".

- Processament Superficial (Estocàstic): Els LLMs funcionen calculant de forma contínua quina és la paraula següent més probable matemàticament segons els milers de milions de textos amb els quals s'han entrenat. No tenen consciència de les conseqüències físiques de les seues paraules ni intencionalitat pròpia.
- Comprensió Profunda (Natural Language Understanding): Perquè una màquina passe del processament textual a una comprensió real, s'està treballant en la integració de Grafs de Coneixement i models d'IA Neuro-simbòlica. Això vincula les

propietats probabilístiques de les paraules amb un model de relacions fixes del món real, minimitzant així les "al·lucinacions" (moments on la IA inventa fets de manera molt convincent).

2. Aplicaciones del PLN:

El Processament del Llenguatge Natural s'ha consolidat com una eina essencial gràcies al seu impacte en l'automatització industrial, la gestió documental i la interacció humà-màquina. A continuació s'analitzen les aplicacions tècniques més rellevants del sector.

2.1 Traductors Automàtics

La traducció automàtica ha viscut un canvi generacional gràcies a l'evolució dels seus enfocaments de disseny:

- Traducció Automàtica Estadística (SMT): Utilitzada en els anys 2000, calculava la probabilitat que una paraula es traduïra per una altra segons corpus bilingües. Mancava de coherència global.
- Traducció Automàtica Neuronal (NMT): Utilitza xarxes neuronals profundes (com arquitectures Encoder-Decoder). Processa la frase sencera com un vector matemàtic continu (incrustació o embedding), preservant el gènere, el nombre, el temps verbal i el registre formal o informal segons el context.


2.2 Anàlisi de Sentiment (Sentiment Analysis)

Consisteix a avaluar de forma algorísmica l'estat emocional o l'opinió expressada en un text lliure.

- Funcionament tècnic: El sistema preprocessa el text (eliminant connectors o stop words) i utilitza un classificador (com un classificador lineal o un model de llenguatge) per assignar una etiqueta de polaritat: Positiu, Negatiu o Neutre.
 - Mètrica d'intensitat: Els models avançats retornen un valor continu (ex: de -1.0 a +1.0) per mesurar el nivell d'enuig o satisfacció d'un usuari en ressenyes o mencions a xarxes socials.
- C) Resum de Texts (Text Summarization)
- L'automatització de la síntesi de documents es divideix en dues tècniques completament diferents:

2.3 Resum de Texts (Text Summarization)

L'automatització de la síntesi de documents es divideix en dues tècniques completament diferents:



- Resum Extractiu: L'algorisme puntua cada frase del text original segons la seua rellevància i densitat d'informació, seleccionant-ne les millors i "retallant-les i enganxant-les" per a formar el resum. No genera paraules noves.
- Resum Abstractiu: Basat en models generatius. La IA llegeix el document sencer, entén el significat conceptual i genera un text completament nou i sintetitzat. És més humà, però presenta risc d'atlucinació de fets.

2.4 Reconeixement de Text (OCR - Optical Character Recognition)

L'OCR és el pont d'unió entre la Visió per Computador i el Processament del Llenguatge Natural. Permet transformar imatges o documents físics digitalitzats en text codificat i editable.

- Fase 1 (Visió): Segmentació de la imatge per a aïllar línies de text, paraules i caràcters individuals, corregint inclinacions o sorolls de fons de l'escaneig.
- Fase 2 (PLN / Classificació): Una xarxa neuronal reconeix la forma dels caràcters i reconstrueix les paraules reals. Els sistemes moderns d'OCR intel·ligent utilitzen diccionaris i context lingüístic per a auto-corregir lletres borroses de manera lògica (ex: saber si diu "casa" o "cosa" pel context de la frase).

2.5 Grans Models de Llenguatge (LLMs - Large Language Models)

Els LLMs representen l'estat de l'art en el PLN. Són models de xarxes neuronals profundes basats en l'arquitectura Transformer que contenen milers de milions de paràmetres matemàtics extensament entrenats amb contingut extret de tot l'internet.

- El poder de la predicció de text: La seua única tasca nativa és predir de manera iterativa el següent fragment de paraula (token) més probable. No obstant això, aquest mecanisme estadístic ha fet emergir capacitats de lògica, traducció, anàlisi i programació de programari.
- Alineació humana (RLHF): Després de l'entrenament massiu amb dades de l'internet, els LLMs es reajusten mitjançant Aprenentatge per Reforç a partir del

Feedback Humà (RLHF). Això garanteix que el model no es limite a "completar l'oració", sinó que actue com a un assistent virtual que segueix instruccions precises, respecta els límits ètics i rebutja peticions perilloses.

Tema 4: Sistemes Robotitzats



- 1 Mètodes i aplicacions de la robòtica
- 2 Modelat i control de robots
- 3 Programació de robots i aplicacions
- 4 Sistemes robotitzats. Disseny i implementació


1 Mètodes i aplicacions de la robòtica

La robòtica és la branca de l'enginyeria i la ciència de la computació que es dedica al disseny, construcció, operació i disposició d'entitats mecàniques programables anomenades robots.

En l'ecosistema actual d'Intel·ligència Artificial i Big Data, els robots han deixat de ser màquines aïllades i cegues per a esdevenir sistemes ciberfísics connectats capaços de percebre el seu entorn i prendre decisions en temps real.

1.1 Classificació fonamental: Robòtica Industrial vs. Robòtica de Serveis

La Federació Internacional de Robòtica (IFR) divideix els sistemes robotitzats en dues grans categories segons el seu entorn operatiu i la finalitat del seu disseny:



1. Robòtica Industrial. Està enfocada a l'automatització de processos de fabricació dins de fàbriques i plantes de producció. Operen en entorns altament controlats (estructurats) on les línies, velocitats i posicions dels objectes estan completament definides de bell antuvi.

- Tasques típiques: Soldadura de carrosseries d'automòbils, pintura amb esprai, muntatge de components electrònics microscòpics o paletitzat de mercaderies pesants.
- Filosofia de disseny: Prioritza la velocitat, la força mecànica, la precisió mil·limètrica repetitiva i el cicle de treball ininterromput. Per motius de seguretat, els robots industrials tradicionals operen en tancaments físics o gàbies equipades amb barreres de llum infraroja que aturen la màquina si un humà hi entra.

2. Robòtica de Serveis. Està dissenyada per a realitzar tasques útils per al benestar dels éssers humans o el manteniment d'equips, sovint fora d'entorns de fabricació industrial. Operen en entorns parcialment estructurats o completament desestructurats (hospitals, llars, carrers, camps de cultiu).

- Tasques típiques: Cirurgia mèdica assistida, neteja de superfícies, vigilància d'edificis, munyiment automàtic en granges o lliurament de paquets a domicili.
-

- Filosofia de disseny: Prioritza l'adaptabilitat davant d'obstacles imprevistos, la mobilitat autònoma, la seguretat en la interacció directa amb humans i la integració de sensors avançats (com LiDAR o visió per computador).

1.2 Tendències d'alta utilitat

Cobots i AGVs / AMRs Dins de la robòtica moderna, la introducció de la Intel·ligència Artificial ha fet emergir dos conceptes clau que estan redefinint les cadenes logístiques i de fabricació:

1. Cobots (Robots Col·laboratius / Collaborative Robots). Un cobot és un robot dissenyat específicament per a compartir l'espai de treball de forma directa i simultània amb els operaris humans, sense necessitat de barreres de seguretat físiques.

- Mecanismes de Seguretat Activa: Disposen de sensors de força i parell integrats a les seues articulacions, superfícies arrodonides i materials embuatats. Si un cobot frega o xoca lleugerament amb un braç humà, l'algorisme de control detecta instantàniament la resistència anòmla i atura el moviment en mil·lisegons per a evitar lesions.
- Programació per Guiatge: A diferència dels robots clàssics que requereixen codi complex, molts cobots es poden programar de forma "directa": un operari agafa el braç mecànic amb la mà, el mou realitzant la trajectòria de la tasca i el robot guarda automàticament els punts a la seua memòria.
- Casos d'ús: Control de qualitat visual col·laboratiu, tasques de recollida i col·locació (pick and place) al costat de treballadors en línies de muntatge electrònic flexible.

2. AGVs (Automated Guided Vehicles) vs. AMRs (Autonomous Mobile Robots). Els sistemes de transport intern de materials han evolucionat dràsticament gràcies a l'autonomia cognitiva:

AGV (Vehicle Guiat Automatitzat): És un robot mòbil clàssic que segueix rutes fixes preestablides. Utilitza mètodes de guiatge rígids com cables soterrats magnètics, tires reflectores a terra o línies de pintura. Si troba un obstacle al seu camí (per exemple, una caixa que ha caigut), l'AGV s'atura i es queda bloquejat esperant que algú retire l'obstacle.

AMR (Robot Mòbil Autònom): És l'evolució intel·ligent de l'AGV. No requereix cap infraestructura física al terra de la fàbrica. Utilitza tècniques de SLAM (Simultaneous Localization and Mapping) mitjançant escàners LiDAR i càmeres 3D per a crear un mapa virtual de l'entorn en temps real. Si un AMR troba un obstacle al seu camí, recalcula instantàniament una ruta alternativa al voltant de l'obstacle per a continuar amb la seua tasca sense detindre la cadena logística.


Mètode de navegació d'un AMR en trobar un obstacle:

Mètode de navegació d'un AMR en trobar un obstacle:

Ruta original:



Ruta calculada per la IA:




2 Modelat i control de robots

Perquè un sistema robotitzat pugui executar ordres de manera precisa (com agafar una peça amb un braç mecànic o seguir una línia a terra), cal descriure matemàticament la seua estructura física i aplicar algorismes que regulen els seus moviments. Aquesta àrea es divideix en el modelat geomètric (cinemàtica), el modelat de forces (dinàmica) i els sistemes de control de llaç tancat (PID).

2.1 Cinemàtica del Robot: Directa i Inversa

La cinemàtica estudia el moviment del robot respecte a un sistema de coordenades de referència, sense tindre en compte les forces que causen aquest moviment. Se centra a analitzar la relació entre els angles de les articulacions del robot i la posició espacial de l'extrem (efector final o pinça).



1. Cinemàtica Directa (Forward Kinematics)

- Objectiu: Determinar la posició (X, Y, Z) i l'orientació de l'efector final a partir dels valors coneguts dels angles de cada articulació o grau de llibertat ($\theta_1, \theta_2, \dots$).
- Complexitat: És un problema algebraic relativament simple que té una solució única. S'utilitzen matrius de transformació homogènia (com el mètode de Denavit-Hartenberg) per a calcular la posició sumant de forma seqüencial els efectes de cada nexa del robot.

2. Cinemàtica Inversa (Inverse Kinematics – IK)

- Objectiu: Calcular els angles de les articulacions ($\theta_1, \theta_2, \dots$) que es necessiten per a portar l'efector final a una posició espacial (X, Y, Z) desitjada.
- Complexitat: És un problema matemàtic altament complex, no lineal i analíticament laboriós.
- Reptes de la IK:
 - **Múltiples solucions:** Un robot pot arribar al mateix punt de l'espai col·locant els seus nexes de maneres diferents (per exemple, un braç humà pot tocar un punt de la taula amb el colze mirant cap avall o cap amunt).
 - **Sense solució:** El punt desitjat es troba fora de l'abast físic de l'espai de treball del robot.
 - **Singularitats:** Configuracions del robot on s'alineen les articulacions i es perden graus de llibertat de moviment de manera instantània, fent que les equacions matemàtiques requerisquen velocitats infinites.

2.2 Dinàmica del Robot

A diferència de la cinemàtica, la dinàmica estudia la relació entre els moviments del robot i les forces o parells torsors (torques) que els produeixen. És essencial per a dissenyar els motors i les estructures mecàniques del robot.

- Variables que considera: La massa de cada nexa del robot, la inèrcia dels


components mecànics, l'efecte de la força de la gravetat segons la posició del braç, la fricció interna dels engranatges i les acceleracions requerides.

- Model dinàmic directe: Calcula les acceleracions resultants d'aplicar forces determinades als motors (s'usa per a fer simulacions físiques per ordinador).
- Model dinàmic invers: Calcula quant de parell (força) han de fer exactament els motors de cada articulació per a poder moure el robot seguint una trajectòria i una velocitat específiques.

2.3 Controladors PID de Posició

Un cop determinats els angles objectiu (mitjançant la cinemàtica) i les forces generals (mitjançant la dinàmica), cal controlar els motors elèctrics de forma individual en temps real per a corregir els errors de posició deguts a pertorbacions (canvis de pes, lliscaments, fricció). Per a fer-ho, s'utilitza el controlador de llaç tancat PID (Proporcional, Integral i Derivatiu).

L'algorisme PID compara contínuament la posició desitjada (Set Point) amb la posició real que indica el sensor del motor (un encoder). La diferència entre ambdues s'anomena error ($e(t)$).



L'ordre final d'actuació que s'envia al motor és la suma de tres accions de control diferenciades:

1. Acció Proporcional (K_p)

Funció: L'ordre és directament proporcional a l'error actual. Si l'error és gran, el motor gira amb molta força; a mesura que el motor s'acosta a la posició desitjada, l'error es fa xicotet i la força disminueix.

Efecte: Ajustar una (K_p) massa alta provoca oscil·lacions i inestabilitat; si és massa baixa, el robot es mou molt lentament.

2. Acció Integral (K_i)

Funció: Suma els errors passats al llarg del temps (acumulació de l'error). S'encarrega d'eliminar l'error en estat estacionari (per exemple, quan la fricció o la gravetat impedeixen que el robot arribi al punt exacte exactament, deixant-lo encallat a pocs mil·límetres de l'objectiu).

Efecte: Si és massa alta, provoca que el robot sobrepassi l'objectiu (overshoot).

3. Acció Derivativa (K_d)

Funció: Examina la velocitat a la qual canvia l'error (la tendència de futur). Actua com a un fre amortidor predictiu: si el robot s'acosta molt ràpidament a la posició objectiu, l'acció derivativa frena el motor de forma anticipada per a evitar un xoc o una sotragada.

Efecte: Augmenta l'estabilitat del sistema però és molt sensible al soroll elèctric dels sensors.

3 Programació de robots i aplicacions

La programació de sistemes robotitzats ha evolucionat des de l'ús de codis tancats i lligats a un fabricant de maquinari específic cap a arquitectures modulars, codi obert i entorns de simulació en 3D que permeten validar els algorismes abans de la seua implantació física.

3.1 Llenguatges Clàssics de Robòtica Industrial


Els fabricants històrics de robòtica industrial han mantingut els seus propis ecosistemes i llenguatges de programació propietaris. Tot i que s'assemblen a llenguatges com C, Pascal o Basic, estan dissenyats específicament per a gestionar el moviment de nexes mecànics, l'activació de pinces i la seguretat en fàbriques.

- **RAPID (ABB):** Un dels llenguatges industrials més estesos. Permet definir tipus de dades estructurades orientades al moviment (com robtarget per a coordenades de posició) i tipus de moviment específics (com MoveL per a trajectòries lineals o MoveJ per a moviments articulars ràpids).
- **KRL - KUKA Robot Language (KUKA):** Basat en l'estructura de Pascal. Està altament integrat amb la cinemàtica del controlador de la màquina i és molt robust en la gestió de rutes complexes d'alta velocitat.
- **AS (Kawasaki) o Karel / TP (Fanuc):** Altres variants de llenguatges de tipus seqüencial tancats que s'executen directament en els terminals d'aprenentatge

físics (Teach Pendants) connectats als armaris de control dels robots.

3.2 Simuladors de Robòtica: Webots i CoppeliaSim

El cost del maquinari robòtic i el perill de trencar un braç mecànic per un error de programació fan imprescindible l'ús d'entorns de simulació virtual. Aquests programes recreen els models en 3D i integren un motor físic que simula la gravetat, la inèrcia, les col·lisions i el comportament dels sensors.



1. CoppeliaSim (Anteriorment conegut com V-REP)

Característiques: És un entorn de simulació altament flexible on cada objecte o component del robot pot tenir el seu propi script adjunt.

Avantatges: Suporta múltiples llenguatges de programació de forma nativa (Lua, Python, C++, MATLAB). És el favorit de l'àmbit acadèmic i d'investigació per a simular sistemes complexos com mans robòtiques articulades, robots caminadors (humanoides o quadrúpedes) i braços industrials interconnectats.

2. Webots

Característiques: Programari de codi obert per a simular robots mòbils, braços industrials i drons. Incorpora una àmplia biblioteca de models de robots comercials ja programats (com els braços d'UR, el robot humanoide NAO o els robots mòbils e-puck).


Avantatges: És molt ràpid a l'hora de calcular el rendiment de sensors de visió (càmeres, LiDAR, sensors de distància infrarojos). Permet programar els controladors en Python i C++, facilitant la integració directa d'algorismes de Machine Learning i visió per computador desenvolupats pels estudiants.

3.3 Introducció a ROS (Robot Operating System)

ROS és l'estàndard de facto en la robòtica avançada a escala mundial. Malgrat el seu nom, no és un sistema operatiu real (com Windows o Linux), sinó un framework de desenvolupament o middleware que s'executa sobre Linux (Ubuntu).

Per què s'utilitza ROS? Abans de ROS, si algú comprava un sensor LiDAR nou, havia d'escriure el codi per a llegir el sensor des de zero i adaptar-lo al seu robot. ROS resol això proporcionant una capa d'abstracció de maquinari, controladors de dispositius comuns, llibreries d'algorismes d'última generació (com navegació SLAM o cinemàtica inversa amb MoveIt) i un sistema de comunicació entre processos.

Conceptes Arquitectònics Clau de ROS:



Nodes: Són xicotets programes independents especialitzats a fer una tasca concreta (ex: un node llegeix les dades del sensor LiDAR, un altre node controla els motors de les rodes i un altre processa les imatges). Un robot pot tenir dotzenes de nodes executant-se a la vegada.

Missatges (Messages): L'estructura de dades que utilitzen els nodes per a compartir informació entre ells (ex: coordenades de posició, imatges, llistes de nombres).

Tòpics (Topics): És el mecanisme de comunicació principal basat en un patró de publicació/subscripció. Un node "publica" dades en un canal anomenat tòpic, i qualsevol altre node que necessite aquesta informació es "subscriu" a eixe tòpic per a rebre-les en temps real sense saber qui les ha enviat.

Serveis (Services): Mecanisme de comunicació basat en petició/resposta (request/reply). S'utilitza per a accions puntuals, com demanar a un robot que active un relé o que reinici el seu mapa.

4. Sistemes robotitzats. Disseny i implementació

El disseny i implementació de sistemes robotitzats requereix una integració precisa entre

components físics (maquinari) i codi (programari). El següent resum estructurat recull els aspectes clau per a la selecció de components i les fases de desenvolupament:

4.1 Selecció d'Actuadors

Els actuadors són els "músculs" del robot. La tria depèn de l'esforç, la velocitat i la precisió necessàries:

- Motors de Corrent Continu (DC): Ideals per a tracció en robots mòbils per la seva alta velocitat. Requereixen reductores i codificadors (encoders) per controlar la posició.
- Servomotors: Perfectes per a articulacions de braços robòtics. Incorporen control de posició intern i mantenen el parell de força en estàtic.
- Motors Pas a Pas (Stepper): Excellents per a moviments precisos de rotació en bucle obert (com en impressores 3D o eixos CNC), però perden eficiència a altes velocitats.
- Actuadors Pneumàtics / Hidràulics: Utilitzats en robòtica industrial pesant o pinces (grippers) on es requereixen forces lineals extremes.

4.2 Selecció de Sensors


Els sensors aporten la percepció de l'entorn ("els ulls i el tacte"). En robòtica mòbil i manipulació destaquen:

- LiDAR (Light Detection and Ranging): Funció: Emet polsos de llum làser per mesurar distàncies exactes en 2D o 3D. Ús clau: Algoritmes de navegació, mapatge (SLAM) i detecció d'obstacles a llarga distància.
- Càmeres RGB-D (Profunditat): Funció: Combinen una imatge en color (RGB) amb un mapa de distància per píxel (Depth) mitjançant llum estructurada o temps de vol (ToF). Ús clau: Reconeixement d'objectes en 3D, visió per computador per a pinces i navegació en interiors.
- IMU (Unitat de Mesura Inercial): Mesura l'acceleració i la velocitat angular per conèixer l'orientació espacial del robot.
- Sensors de Força / Parell: Situats a l'extrem del braç robòtic per mesurar la resistència en interactuar amb objectes.

4.3 Cicle de Disseny Maquinari/Programari (HW/SW)

El desenvolupament d'un robot segueix un cicle iteratiu en paral·lel anomenat disseny de

co-enginyeria:



1) Definició de Requisits: Fixar tasques, càrrega útil (payload), velocitat, autonomia i entorn de treball.

2) Disseny del Maquinari (HW):

- Mecànic: Modelat en 3D (CAD) de l'estructura, selecció de materials i anàlisi de tensions.
- Electrònic: Disseny de plaques de circuit imprès (PCB), línies de potència i aïllament de soroll dels motors.


3) Disseny del Programari (SW):

- Baix Nivell: Firmware per al control en temps real dels motors i lectura de sensors (habitualment en C/C++ sobre microcontroladors o RTOS).
- Alt Nivell: Control de missió, navegació i visió artificial utilitzant frameworks com el Robot Operating System (ROS 2).

4) Simulació: Abans de fabricar, es valida tot el conjunt en entorns virtuals com Gazebo o Webots per estalviar costos i evitar trencaments.

5) Integració i Proves: Proves progressives en el prototip físic (primer components individuals, després subsistemes i finalment el robot sencer).

Tema 5: Sistemes Experts




1. Dinàmica dels sistemes experts
2. Estructures elementals
3. Representar i simular comportaments bàsics
4. Estratègies de control
5. Aplicacions i tendències

1. Dinàmica dels sistemes experts

Els sistemes experts són programes d'intel·ligència artificial dissenyats per emular la capacitat de decisió d'un especialista humà en un domini molt concret. La seva dinàmica es basa en com es captura, s'estructura i s'actualitza aquest saber tecnològic.

1.1. El Cicle de Vida d'un Sistema Expert

El desenvolupament d'aquests sistemes és incremental i iteratiu, ja que el coneixement humà és complex de formalitzar a la primera. Es divideix en cinc fases principals:



1) Identificació i Viabilitat: Es defineix l'abast del problema, es busquen els experts humans i es comprova si el retorn de la inversió justifica el cost del projecte.

2) Conceptualització: S'analitzen els conceptes clau, les relacions de causa-efecte i el tipus de dades que utilitza l'expert per resoldre el problema.

3) Formalització: Es tria l'estructura de representació del coneixement (com ara regles Si-Llavors, xarxes semàntiques o lògica difusa) i l'arquitectura del motor d'inferència.

4) Implementació i Validació: Es programa el prototip i es posa a prova amb casos reals. L'expert humà avalua si les conclusions de la màquina coincideixen amb el seu criteri professional.

5) Manteniment: Monitoratge continu i actualització de la base de coneixements per evitar l'obsolescència.

1.2 Adquisició del Coneixement de l'Expert Humà

Aquest procés és el coll d'ampolla de l'enginyeria del coneixement. Consisteix a extreure el saber "tàcit" de l'expert (l'experiència pràctica) per transformar-lo en coneixement "explícit" (codificable).

L'enginyer del coneixement (Knowledge Engineer) utilitza diverses tècniques d'extracció:

- Entrevistes Directes:
 - No estructurades: Converses obertes per entendre el domini de manera general.
 - Estructurades: Qüestionaris tancats enfocats a resoldre un subproblema concret.
- Anàlisi de Protocols (Think-Aloud): Es demana a l'expert que resolgui un cas real en veu alta, explicant pas a pas cada decisió i pensament que li passa pel cap.

- Observació de l'Acció: El tecnòleg observa l'expert treballant en el seu entorn habitual sense interrompre'l, anotant les eines i patrons que fa servir.
- Mètodes de Reixeta (Grid Method / Repertory Grid): Tècnica psicològica on l'expert classifica elements del seu domini segons atributs específics per identificar relacions ocultes o subtils.


1.3 Manteniment i Evolució del Sistema

Un sistema expert no és estàtic; si el món canvia o apareixen noves normatives, el sistema esdevé inútil si no s'actualitza. El manteniment inclou tres tasques bàsiques:

- Refinament de Regles: Corregir errors de lògica detectats durant l'ús diari o afegir excepcions a les regles existents.
- Gestió de la Inconsistència: Quan s'afegeixen regles noves, cal comprovar de forma automatitzada que no entrin en contradicció directa amb les regles que ja funcionaven.
- Modularització: Organitzar la base de coneixements en blocs o "paquets" temàtics independents. D'aquesta manera, si un protocol canvia, només s'ha de modificar un mòdul sense alterar la resta de l'estructura del programari.

2. Estructures elementals

Un sistema expert es divideix de forma modular per separar el saber tècnic dels mecanismes de raonament. L'arquitectura clàssica d'aquests sistemes es fonamenta en tres estructures elementals:



2.1 Base de Coneixement (BC)

És el magatzem on es desa tota la informació, l'experiència i les regles heurístiques

formalitzades del domini concret. No conté codi de programació procedural, sinó dades declaratives. Es divideix habitualment en dues parts:

- Base de fets (Memòria de treball): Conté les dades reals i conegudes del problema actual que es vol resoldre (per exemple: "El pacient té febre" o "La pressió és de 4 bars"). És dinàmica i canvia en cada consulta.
- Base de regles: Conté el saber abstracte de l'expert humà en forma de lògica condicional (SI condició LLAVORS acció/conclusió). És estàtica i només canvia durant el manteniment del sistema.

2.2 Motor d'Inferència

És el component actiu o el "cervell" del sistema. S'encarrega d'analitzar els fets introduïts, lligar-los amb les regles de la base de coneixement i treure noves conclusions lògiques. Utilitza principalment dues estratègies de raonament:

Encadenament cap endavant (Forward Chaining): S'inicia a partir dels fets coneguts. El motor cerca quines regles es compleixen amb aquests fets per generar nous fets, fins a arribar a una conclusió final. S'utilitza per a diagnòstics i anàlisis de dades.

Encadenament cap enrere (Backward Chaining): S'inicia a partir d'una hipòtesi o objectiu final. El motor camina a la inversa per veure si existeixen els fets necessaris que donin suport a aquesta hipòtesi. S'utilitza per a la validació de teories o planificació.

2.3 Interfície d'usuari

És l'entorn de comunicació bidireccional entre la persona (que pot no ser informàtica) i la màquina. Desenvolupa tres funcions fonamentals: Recollida de dades:

- Formula preguntes interactives a l'usuari per omplir la base de fets inicial.
- Presentació de resultats: Mostra la conclusió final o la recomanació del sistema d'una forma intel·ligible.
- Mòdul d'explicació (Justifier): És una característica única dels sistemes experts. Permet a l'usuari preguntar "Per què?" el sistema demana una dada o "Com?" ha arribat a una determinada conclusió, desglossant el camí lògic que ha seguit el motor d'inferència.

3. Representar i simular comportaments bàsics:

Per representar i simular la ment d'un expert humà, la informació s'ha d'estructurar de forma que els ordinadors en puguin entendre el significat (semàntica) i les relacions.

3.1 Grafs de Coneixement

Un graf de coneixement és una xarxa de dades interconnectades que utilitza una estructura de nodes (entitats o conceptes) i arestes (relacions entre ells).

- Estructura de Tripletes: La informació es desa sempre en format Subjecte — Relació —> Objecte.
- Exemple: [Grip] — ésUn —> [Virus] o [Febre] — ésSímtomaDe —> [Gripe].
- Utilitat: Permet als cercadors i sistemes de recomanació navegar per milions de dades connectades de forma extremadament ràpida.

3.2 Ontologies i Protégé

Una ontologia és el model formal que defineix quines coses poden existir en un domini (classes), quines propietats tenen i com es relacionen. És el "diccionari de regles" que dona sentit a un graf de coneixement.

- L'eina estàndard de la indústria per dissenyar-les és l'editor de codi obert Protégé. En aquesta aplicació es defineixen tres elements:
- Classes (Conceptes): Jerarquies de categories (Exemple: La classe Medicament és una subclasse de Tractament).
- Propietats d'Objecte (Object Properties): Relacions entre classes (Exemple: téSímtoma connecta la classe Malaltia amb la classe Símtoma).
- Propietats de Dades (Data Properties): Atributs literals o numèrics de les classes (Exemple: edatMínima té un valor de tipus enter).
- Instàncies (Individuals): Els objectes reals del món (Exemple: Paracetamol és una instància concreta de la classe Medicament).
- Raonador (Reasoner): Protégé inclou motors com Hermit o Pellet que analitzen l'ontologia per detectar errors lògics o deduir noves relacions automàticament.

3.3 Regles de Producció

Són la base per a la simulació del comportament en el motor d'inferència. Tradueixen el coneixement declaratiu en accions executives mitjançant la lògica condicional. Tenen l'estructura formal SI <Premisses/Antecedents> LLAVORS <Accions/Conseqüents>.

Exemple de simulació d'una regla:

Fets actuals en memòria: [El pacient té febre alta] i [El pacient té tos seca].

Regla de producció activa: SI (pacient.febre == "alta") I (pacient.tos == "seca")
LLAVORS (afegir_fet(pacient.sospita, "Infecció respiratòria"))

Resultat de la simulació: El sistema executa l'acció del LLAVORS i injecta de manera automàtica un nou fet a la memòria de treball, que pot activar noves regles en cadena.

4. Estratègies de control

En els sistemes experts i de resolució de problemes, les estratègies de control defineixen l'ordre en què s'explora l'espai d'estats i com es gestiona l'execució del coneixement quan s'activen múltiples opcions alhora.

4.1 Control de la Cerca en l'Arbre de Decisions

Quan el sistema busca una solució, l'espai de situacions es pot representar com un arbre on cada node és un estat i cada branca és una acció o regla. El control determina com es viatja per aquest arbre:

- Cerca No Informada (Cega):
 - En amplada (BFS): S'examinen tots els nodes d'un nivell abans de passar al següent. Garanteix trobar el camí més curt, però consumeix molta memòria.
 - En profunditat (DFS): S'explora una branca fins al fons abans de fer marxa enrere (backtracking). És eficient en memòria, però pot quedar atrapat en branques infinites.
- Cerca Informada (Heurística):
 - Algorisme A*: Utilitza una funció d'avaluació $f(n) = g(n) + h(n)$, on $g(n)$ és el cost real acumulat i $h(n)$ és una estimació (heurística) del cost restant fins a l'objectiu. Troba la ruta òptima minimitzant l'esforç.
 - Cerca Primer el Millor (Best-First): Selecciona el node següent basant-se exclusivament en l'estimació de quina branca sembla més propera a la solució ($h(n)$).
- Direcció del Control: Encadenament cap endavant: Es mou de les arrels (fets inicials) cap a les fulles (objectius). Encadenament cap enrere: Es mou de les fulles (hipòtesis a demostrar) cap a les arrels (fets que les validen).

4.2 Resolució de Conflictes en Regles Simultànies

Durant el cicle d'execució d'un motor d'inferència, és habitual que els fets de la memòria de treball activin els antecedents de diverses regles al mateix temps. El conjunt de regles llistes per executar-se s'anomena conjunt de conflicte.

Com que el sistema generalment només pot executar una regla per cicle, s'apliquen

estratègies de resolució de conflictes per triar la millor:

- Prioritat Estàtica (Salència): L'enginyer del coneixement assigna manualment un valor numèric fix a cada regla (per exemple, Prioritat = 100). La regla amb la puntuació més alta s'executa primer.
- Especificitat (Més específica primer): Si dues regles coincideixen, es tria la que té més condicions en el seu antecedent. Una regla amb tres condicions és més precisa i concreta que una que només en té una de general.
- Recència (Novetat de les dades):
 - De fets: Es dona prioritat a la regla que s'activa utilitzant els fets introduïts o deduïts més recentment en el temps.
 - De regles: S'executa la regla que s'ha afegit o modificat més recentment a la base de coneixement.
- Refractarietat (No repetició): Una regla que ja s'ha executat amb uns fets concrets no es pot tornar a activar amb exactament els mateixos fets. Això evita que el motor d'inferència entri en un bucle infinit de simulació.
- Estratègia MEA (Means-Ends Analysis): Una variant que posa el focus principal en la recència del primer fet de la condició de la regla, ajudant a mantenir el sistema enfocat en la línia de raonament o objectiu actual.

5. Aplicacions i tendències

L'evolució dels sistemes experts mostra la transició des de solucions pioneres basades en regles rígides fins a la hibridació moderna amb la intel·ligència artificial profunda.

5.1 Diagnòstic Mèdic Clàssic: MYCIN

Creat a la Universitat de Stanford als anys 70, MYCIN és el sistema expert clàssic més emblemàtic de la història de la IA.

- Propòsit: Diagnosticar infeccions bacterianes greus a la sang (com la meningitis) i recomanar la dosi correcta d'antibiòtics.
- Funcionament: Utilitzava un motor d'encadenament cap enrere (backward chaining) amb unes 600 regles de producció.
- Gestió de la incertesa: Va introduir els Factors de Certesa (CF), una aproximació numèrica entre -1 (fals absolut) i 1 (certesa absoluta) per avaluar hipòtesis quan les dades mèdiques eren incompletes.
- Llegat: Malgrat que mai es va utilitzar en la pràctica clínica real per motius legals i ètics, va demostrar una precisió similar o superior a la de molts especialistes humans de l'època.

5.2 Configuradors de Productes Industrials


En la indústria manufacturera moderna (automoció, maquinària, aeronàutica), els sistemes experts són el motor dels configuradors de productes complexos sota la metodologia Configure-to-Order (CTO).

- El Problema: Un producte industrial (com un camió elèctric o un quadre elèctric d'alta tensió) té milers de combinacions possibles de peces, però no totes són compatibles entre si.
- Solució per regles: La base de coneixement conté les restriccions tècniques de disseny (Exemple: Si tries el motor X, LLAVORS el xassís ha de ser el Y i NO es pot muntar la bateria Z).
- Integració de negoci: Es connecten directament amb els sistemes ERP i PLM de les fàbriques. Quan un client configura un producte a la web, el sistema valida la viabilitat tècnica instantàniament, calcula el preu i genera la llista de materials exacta per a la línia de producció.

5.3 La Tendència Futur: IA Neuro-Simbòlica

La limitació dels sistemes experts clàssics (simbòlics) és que no poden aprendre sols ni processar dades no estructurades (imatges, àudio). La limitació de l'Aprenentatge Profund (Deep Learning o IA subsimbòlica) és que és una "caixa negra" que comet errors absurds i no pot explicar el seu raonament.

La IA Neuro-Simbòlica fusiona el millor d'ambdós mons:



Com funciona?:

- La part "Neuro" (Deep Learning): S'encarrega de la percepció i l'extracció de patrons. Per exemple, processa radiografies per detectar taques o llegeix sensors LiDAR en robòtica.
- La part "Simbòlica" (Sistemes Experts / Ontologies): Rep els conceptes detectats per la xarxa neuronal i hi aplica la lògica de negoci, les lleis físiques o els protocols mèdics per prendre la decisió final.

Avantatges clau:

- Explicabilitat: El sistema pot justificar la decisió final mitjançant un arbre de lògica humana.
- Robustesa: Evita que les al·lucinacions de la IA generativa o els errors del Deep Learning violin regles de seguretat crítiques de la vida real.
- Eficiència de dades: Necessita molts menys exemples per entrenar-se, ja que les regles fonamentals del món ja estan programades en la part simbòlica.

Tema 6: Principis Legals i Ètics de la IA



- 1 Deontologia professional en Intel·ligència Artificial
- 2 Privacitat de dades
- 3 Protecció davant d'errades
- 4 Principis ètics de la IA i la Llei de la IA de la UE
- 5 Biaixos de gènere en la IA i el Big Data

1 Deontologia professional en Intel·ligència Artificial

La deontologia professional determina el conjunt de deures, principis i normes ètiques que han de guiar la conducta dels professionals d'una disciplina del coneixement. En l'àmbit de la Intel·ligència Artificial i el Big Data, les decisions tècniques influeixen directament sobre la privacitat, els drets civils, l'ocupació i la seguretat de les persones. Per tant, l'exercici de la professió demana un compromís que va molt més enllà de l'optimització de mètriques d'exactitud o rendiment de codi.

1.1 El paper de l'enginyer/a i analista de dades

Els enginyers de Machine Learning, científics de dades i analistes actuen com a arquitectes de sistemes de decisió automatitzada. La seua responsabilitat professional abasta totes les fases del cicle de vida d'un model d'IA:

- Responsabilitat en la recollida de dades: Garantir que la informació d'entrenament prové de fonts lícites, respectant el consentiment dels usuaris i avaluant críticament si les dades històriques perpetuen discriminacions.
- Supervisió de la qualitat tècnica: Evitar el desplegament de models deficients, poc provats o inestables, sobretot en entorns crítics de salut, finances o automoció.
- Transparència algorísmica: Rebutjar el disseny de sistemes "caixa negra" (black box) inescrutables quan s'apliquen a la concessió de crèdits, selecció de personal o àmbits judicials, assegurant que les decisions es puguin explicar de manera accessible per a persones no tècniques.
- Deure de denúncia (Whistleblowing): Negar-se de manera explícita a desenvolupar projectes destinats a la manipulació psicològica d'usuaris, la desinformació sistemàtica, la vigilància massiva illegal o la creació d'armament autònom no supervisat.

1.2 Codis de conducta i marcs ètics internacionals

A causa de la naturalesa global del desenvolupament del programari, diferents organitzacions de prestigi internacional han codificat marcs ètics i normatius per a estandarditzar el comportament de la professió.

a) Codi Ètic de l'ACM (Association for Computing Machinery)

L'ACM manté un dels codis deontològics més influents del sector de la computació. Els seus pilars aplicats a la IA inclouen:

- Contribuir a la societat i al benestar humà: Reconéixer que totes les persones són parts interessades en la informàtica.

- Evitar el dany: Minimitzar els efectes secundaris negatius dels algorismes, com la pèrdua involuntària d'informació o els biaixos.
- Ser honest i de confiança: Reconeixement obert de les limitacions i capacitats reals dels models davant dels clients i la societat.
- Respectar la privacitat: Implementar de manera proactiva mesures tècniques per a protegir la identitat de les persones que nodreixen els conjunts de dades.

b) Codi Ètic d'IEEE sobre Sistemes Intel·ligents i Autònoms (IEEE Global Initiative)


L'Institut d'Enginyers Elèctrics i Electrònics proposa el principi de Disseny Impulsat pels Valors (Value-Driven Design), establint que els sistemes autònoms s'han de programar per a respectar de manera estricta els Drets Humans:

- Responsabilitat jurídica (Accountability): Sempre s'ha de poder traçar quina entitat o quin programador és responsable del comportament erroni del sistema.
- Seguretat operacional: Un robot o un agent virtual mai no ha de posar en perill la integritat física de cap ésser humà, un principi fortament connectat amb el control preventiu de fallades.

c) Les directrius ètiques de la Unió Europea per a una IA fiable

El Grup d'Experts d'Alt Nivell de la Comissió Europea va establir un dels marcs pràctics més utilitzats a escala industrial a Europa, definint que una IA ha de ser Fiable (Trustworthy AI) complint tres components durant el seu cicle de vida: Lícita:

- Complir amb totes les lleis i reglaments aplicables (com el Reglament General de Protecció de Dades - RGPD i la Llei de la IA de la UE).
- Ètica: Garantir el respecte dels principis ètics fonamentals. Robusta: Tant des de la perspectiva tècnica (evitar ciberatacs i inestabilitat matemàtica) com social.



2 Privacitat de dades

En l'era del Big Data, la captura, emmagatzematge i processament massiu d'informació ha convertit la privacitat de les dades en un dels majors reptes jurídics i tecnològics. Els professionals d'Intel·ligència Artificial han de conèixer el marc legal europeu i aplicar tècniques d'enginyeria de privacitat per a protegir la identitat de les persones sense destruir el valor analític de la informació.


2.1 El Reglament General de Protecció de Dades (RGPD)

El RGPD (Reglament UE 2016/679) és el marc normatiu de referència a tota la Unió Europea per a la protecció de les dades personals. Estableix un control estricte sobre com les organitzacions i els models d'IA poden recopilar i utilitzar la informació dels ciutadans.

- Dada Personal: Qualsevol informació relativa a una persona física identificada o identificable (com el nom, DNI, localització GPS, adreça IP o l'historial clínic).
- Principi de Limitació de la Finalitat: Les dades s'han de recollir amb fins determinats, explícits i legítims. No es poden utilitzar posteriorment per a entrenar una IA en tasques que l'usuari no haguera autoritzat de manera clara.
- Principi de Minimització de Dades: Un model o base de dades només ha de recollir les dades estrictament necessàries per a la seua funció. Exemple: Si una aplicació prediu el preu de l'assegurança d'un cotxe basant-se en l'edat i el tipus de vehicle, és il·legal que emmagatzeme l'orientació sexual o la religió de l'usuari.
- Privacitat des del Disseny i per Defecte (Privacy by Design): L'enginyer de dades ha d'integrar les mesures de protecció a l'arquitectura del programari des de la primera línia de codi, i no com un afegit d'última hora.

2.2 Anonimització vs. Pseudonimització

El RGPD distingeix clarament entre dues tècniques de modificació de dades segons el seu nivell de reversibilitat:



1. Pseudonimització. Consisteix a substituir els identificadors directes d'una persona (com el seu nom o el seu DNI) per un codi artificial, un àlies o un valor hash.

Característica clau: És un procés reversible. Si un enginyer té accés a una "taula de correspondències" o clau oculta separada de manera segura, pot tornar a enllaçar els codis amb les identitats reals de les persones.

Impacte legal: Com que és reversible, les dades pseudonimitzades continuen considerant-se "dades personals" i estan subjectes a totes les obligacions i sancions del RGPD.

2. Anonimització. Consisteix a aplicar una modificació irreversible a les dades, de manera que siga absolutament impossible identificar la persona física darrere del registre mitjançant qualsevol tecnologia actual, ni tan sols utilitzant informació addicional de tercers.

Tècniques clàssiques: Supressió de registres, agregació de valors (ex: canviar edats exactes per rangs de "30 a 40 anys") o addició de soroll estadístic elemental.


Impacte legal: Un cop un conjunt de dades està correctament anonimitzat, deixa de ser considerat "dada personal" i queda fora de l'àmbit del RGPD, permetent la seua lliure utilització per a l'entrenament de models de Machine Learning.

2.3 Privacitat Diferencial (Differential Privacy)

Malgrat que l'anonimització tradicional esborre els noms, els models de IA i Big Data són tan potents que poden realitzar atacs de reidentificació. Si un atacant creua un dataset anonimitat d'hospitals amb un directori públic (com el cens electoral), pot deduir amb exactitud la identitat d'un malalt enllaçant dades indirectes (quasidentificadors) com el codi postal, l'edat i el gènere.

Per a evitar-ho, va sorgir la Privacitat Diferencial, una definició matemàtica rigorosa de la privacitat, popularitzada per Cynthia Dwork el 2006.

Com funciona? No és una eina única, sinó un marc matemàtic. Consisteix a introduir una quantitat mesurada i controlada de soroll matemàtic (normalment basat en la distribució de Laplace o de Gauss) directament a les dades o al resultat de les consultes a la base de dades.



La quantitat de privacitat es regula mitjançant un paràmetre matemàtic anomenat pressupost de privacitat (ϵ o Èpsilon):

- Si ϵ és molt xicotet: S'afegir molt de soroll. La privacitat de l'individu és màxima, però les dades perden certa utilitat pràctica per a la IA.
- Si ϵ és molt gran: S'afegir poc de soroll. La IA obté resultats idèntics als reals, però es posa en perill la privacitat de l'usuari.

La regla d'or de la privacitat diferencial: El resultat de qualsevol consulta analítica feta sobre un conjunt de dades ha de ser pràcticament idèntic tant si s'inclou la informació d'una persona concreta en el dataset com si no s'inclou. D'aquesta manera, cap atacant pot inferir si un individu ha participat o no en un estudi mèdic o en una enquesta.

Exemples d'ús industrial: Empreses com Apple, Google i el Cens dels Estats Units utilitzen privacitat diferencial per a recopilar estadístiques d'ús de teclats mòbils, telemetria d'errors o dades de població sense emmagatzemar o exposar els patrons privats de cap ciutadà individual.

3 Protecció davant d'errades

El desplegament de models d'Intel·ligència Artificial en entorns del món real comporta el risc inherent que el sistema cometa errors de predicció o de comportament. Per a garantir la fiabilitat i mitigar l'impacte d'aquestes fallades, la disciplina es recolza en tres línies de defensa: mètodes de validació estadística durant el disseny (validació creuada), controls d'avaluació externs (auditories d'algorismes) i arquitectures de programari/maquinari resilient (sistemes fail-safe).


3.1 Mètodes de Validació Creuada (Cross-Validation)

En l'aprenentatge automàtic, un dels errors més comuns és el sobreajust (overfitting),

que es produeix quan un model aprèn de memòria les dades d'entrenament (incloent-hi el seu soroll) però és incapaç de generalitzar correctament davant de dades noves. La validació creuada és una tècnica estadística dissenyada per a avaluar de manera realista la capacitat de generalització d'un algorisme i assegurar que les seues mètriques d'èxit siguin estables.

Validació Creuada de K Tandes (K-Fold Cross-Validation) És el mètode estàndard en el sector. Consisteix en el següent procediment:

- Es divideix el conjunt de dades original de forma aleatòria en K parts (o trossos) de la mateixa mida (normalment $K=5$ o $K=10$).
- L'algorisme s'entrena durant K iteracions diferents.
- En cada iteració, s'utilitza una part diferent com a conjunt de prova (test set) i les K-1 parts restants es combinen per a formar el conjunt d'entrenament (training set).
- Es calcula la mètrica de rendiment (com l'exactitud o l'error quadràtic) per a cada iteració i es fa la mitjana final de totes elles.



Validació Creuada Estratificada. S'utilitza en problemes de classificació quan les classes estan desequilibrades (per exemple, un dataset mèdic amb un 99% de pacients sans i un 1% de malalts). Aquest mètode garanteix que cada tros (fold) continga exactament la mateixa proporció de cada classe que el dataset original, evitant biaixos en l'avaluació.

3.2 Auditories d'Algorismes

Una auditoria d'algorismes és una avaluació sistemàtica, independent i estructurada d'un sistema d'IA per a verificar que funciona de manera segura, ètica, legal i d'acord amb els

requisits del negoci o de les normatives (com l'AI Act de la Unió Europea).

Les auditories s'enfoquen en tres dimensions de control:


- Auditoria de Rendiment i Robustesa: Posa a prova el comportament de la IA davant de condicions extremes. S'utilitzen atacs adversaris (canvis subtils en les dades d'entrada dissenyats específicament per a enganyar la IA) per a comprovar si el model manté la seua estabilitat.
- Auditoria de Biaix i Equitat (Fairness): Analitza de forma estadística si les prediccions de la IA perjudiquen o beneficien de manera sistemàtica determinats grups demogràfics protegits (com per exemple, per motius de gènere, ètnia o edat).
- Auditoria de Traçabilitat i Explicabilitat (XAI): Verifica que l'empresa conserve registres detallats d'on provenen les dades, qui va entrenar el model i com s'ha estructurat la presa de decisions, de manera que es puguin auditar les causes d'un error en cas de litigi judicial.

3.3 Sistemes Crítics de Seguretat i Arquitectures Fail-Safe

Quan un sistema d'IA s'implanta en un entorn crític de seguretat on un error pot provocar pèrdues humanes o catàstrofes econòmiques (com un vehicle autònom, un sistema d'administració de fàrmacs a l'hospital o el control d'una central nuclear), el programari s'ha de dissenyar sota principis de resiliència estricta.

El Principi Fail-Safe (Segur enfront de fallades) Un sistema de seguretat fail-safe és un mecanisme de disseny que garanteix que, en cas que es produïska una fallada elèctrica, de maquinari, de sensors o un error lògic de la IA, el sistema transite automàticament cap a un estat completament segur per a les persones, aturant l'operació si és necessari.

Les tècniques d'implementació clau en sistemes crítics d'IA inclouen:



Redundància de maquinari i sensors (Fusió de sensors): Un vehicle autònom no pot dependre només d'una càmera per a frenar. Si la pluja o la boira tapen la càmera (fallada de dades), el sistema ha de disposar de canals redundants independents (com radars i LiDAR) per a seguir funcionant sense perdre la percepció de l'entorn.

Sistemes de control de suport clàssics (Backups): Els models de Deep Learning es complementen amb sistemes d'automatització tradicionals i deterministes basats en regles codificades ràpides. Per exemple, si la IA d'un braç robòtic col·laboratiu pateix una "al·lucinació" en la seua cinemàtica i intenta fer un moviment a velocitat prohibit, un interruptor físic analògic o una regla de programari de baix nivell talla el corrent dels motors a l'instant, independentment del que diga la IA.

Desconnexió controlada i degradació de funcions (Graceful Degradation): Si l'algorisme detecta que les seues mètriques de confiança davant d'una situació real cauen per davall d'un llindar de seguretat, la IA no ha d'intentar "endevinar". El sistema ha d'emetre una alerta d'emergència immediata perquè un operari humà agafe el control manual (enfocament Human-in-the-loop), o bé reduir la seua velocitat de forma preventiva i col·locar-se en una posició d'estacionament segur.

4 Principis ètics de la IA i la Llei de la IA de la UE

La tendència reguladora a nivell mundial exigeix que els principis ètics de la Intel·ligència Artificial deixen de ser recomanacions voluntàries i es convertisquen en requisits tècnics i legals d'obligat compliment. La Llei de la IA de la Unió Europea (Reglament UE 2024/1689) n'és el màxim exponent, regulant l'ús d'aquesta tecnologia mitjançant un enfocament basat en el risc dels sistemes.

4.1 Transparència i Explicabilitat (XAI - Explainable AI)

A mesura que els algorismes es tornen més complexos (com els models de Deep Learning), apareix el problema de la caixa negra: el sistema encerta la predicció, però l'enginyer no pot traçar el camí lògic intern que ha seguit el model per a prendre eixa decisió.

- **Transparència:** Obligació de dissenyar els sistemes de manera que s'informe explícitament l'usuari cada vegada que interactua amb una IA o consumeix continguts generats de forma sintètica (com imatges o textos generats per IA). Des de l'entrada en vigor de les obligacions del Reglament Europeu (Article 50), els proveïdors han d'incloure marques d'aigua digitals (watermarking) legibles per màquina per a identificar clarament les falsificacions profundes (deepfakes).
- **Explicabilitat (XAI):** Conjunt de tècniques i mètodes d'enginyeria de programari dirigits a fer que els resultats dels models de Machine Learning siguin comprensibles per als sers humans (auditors, jutges o metges).
Mètode SHAP (SHapley Additive exPlanations): Algorisme basat en la teoria de jocs que puntua quant ha influït exactament cada variable d'entrada en el resultat final d'un model.
Mètode LIME: Tècnica que entrena un model interpretable simple al voltant d'una predicció concreta per a explicar el comportament local d'un algorisme de caixa negra.

4.2 Equitat (Fairness) i prevenció de discriminacions


L'equitat en la IA garanteix que els algorismes prenguen decisions lliures de biaixos sistemàtics que puguin discriminar col·lectius de persones per raó de gènere, edat, ètnia o religió.

- **Biaix de dades:** Si un sistema de selecció de personal d'IA s'entrena amb l'historial de contractacions de l'empresa dels últims 20 anys, i històricament només s'hi contractaven homes, el model n'extraurà el patró estadístic que "ser home és un requisit d'èxit" i descartarà de forma automàtica les dones.
- **Mitigació tècnica en el cicle de vida:**
 - **Preprocessament:** Tècniques de desbiatjat (debiasing) de bases de dades abans de l'entrenament, eliminant variables protegides o reequilibrant les mostres.
 - **In-processament:** Inclusió de penalitzacions matemàtiques en la funció de pèrdua de l'algorisme perquè prime la paritat estadística en els resultats.
 - **Postprocessament:** Ajustar els llindars de decisió final un cop el model ha acabat d'entrenar per a garantir resultats equitatius entre grups.

4.3 Supervisió Humana (Human Oversight) i la Llei de la IA de la UE

L'AI Act de la UE estableix el principi que els humans han de mantenir sempre el control

sobre les decisions més crítiques que prenguen les màquines. El reglament classifica els sistemes en quatre nivells de risc de manera estricta:



Requisits d'Obligat Compliment per als sistemes d'Alt Risc

Els sistemes d'Alt Risc (com els algorismes que avaluen exàmens, trien candidats en un lloc de treball o gestionen infraestructures crítiques) s'han de dissenyar de forma nativa complint l'Article 14 del reglament, el qual exigeix mesures que permeten a l'operador humà:

Comprendre les limitacions: L'operador ha d'entendre les capacitats reals del model i evitar el biaix d'automatització (la tendència humana de confiar cegament en la recomanació del programari).

Ignorar o anul·lar la sortida: L'humà ha de tenir la potestat legal i tècnica de desestimar el resultat de la IA en qualsevol moment.

Botó de parada d'emergència: El programari ha d'incloure interfícies clares que permeten detindre l'operació del sistema per complet cap a un estat seguretat enfront de fallades (fail-safe).

5 Biaixos de gènere en la IA i el Big Data

El desenvolupament de models d'Intel·ligència Artificial es basa en l'aprenentatge a partir de grans volums de dades (Big Data). Si aquestes dades contenen desequilibris o reflecteixen prejudicis socials, l'algorisme no només els aprendrà, sinó que els automatitzarà i amplificarà a gran escala. Els biaixos de gènere representen un dels problemes ètics més estesos en l'ecosistema tecnològic actual.

5.1 Identificació de biaixos en conjunts de dades (Datasets)

El primer lloc on s'introdueix el biaix és en la selecció, recollida i etiquetatge de les dades d'entrenament. Un model és tan bo com ho siguin les seues dades (Garbage in, garbage out).

- Subrepresentació de dades (Biaix de mostreig): Es produeix quan un grup de la població està infrarepresentat numèricament en el dataset.
Exemple en salut: Tradicionalment, molts assajos clínics de malalties cardiovasculars s'han fet majoritàriament amb hòmens. Si s'entrena una IA de diagnòstic amb aquestes dades, el model fallarà en detectar infarts en dones, ja que els símptomes clínics poden manifestar-se de manera diferent entre gèneres.
- Biaix d'etiquetatge (Labeling bias): Els conjunts de dades solen ser etiquetats per humans (com en el cas d'imatges per a visió per computador). Si les persones que etiqueten projecten els seus propis estereotips sobre les imatges, la IA interioritzarà eixa distorsió.
Exemple clínic: Un estudi va demostrar que algorismes de visió demanats per a classificar imatges de persones cuinant assignaven automàticament l'etiqueta "dona" a la foto, fins i tot si la persona cuinant era un home, a causa de la descompensació del dataset original.


5.2 Biaixos històrics d'entrenament

El biaix històric es produeix quan les dades utilitzades per a l'entrenament són exactes respecte a la realitat, però reflecteixen una situació històrica de desigualtat, discriminació o exclusió social que es vol corregir.

- Models de Llenguatge (LLMs) i Traducció: Els models es nodreixen de milers de milions de pàgines web, llibres i diaris del passat. El llenguatge reflecteix les estructures socials històriques.
Exemple clàssic en traducció: Traduir de llengües neutres (com el turc o l'hongarés, que no tenen gènere en els pronoms) a l'anglès o al català. Durant anys, els traductors automàtics convertien "O bir doktor" (ell/ella és metge) com "Ell és metge", i "O bir hemşire" (ell/ella és infermera) com "Ella és infermera". La IA assumia l'estereotip professional perquè estadísticament era la combinació més freqüent en els textos històrics d'internet.
- Sistemes de contractació de personal (Recursos Humans): El conegut cas de l'algorisme de contractació d'Amazon (retirat el 2018) va exemplificar el biaix històric. El sistema es va entrenar amb els currículums dels enginyers contractats durant els 10 anys anteriors (majors de l'àmbit de les enginyeries on la presència masculina era superior). L'algorisme va aprendre a penalitzar qualsevol currículum que incloguera la paraula "dona" (per exemple, "capitana de l'equip femení d'escacs"), descartant automàticament el talent femení de manera sistemàtica.

5.3 Tècniques de mitigació dels biaixos de gènere

Per a corregir aquests errors, els analistes i enginyers de dades han d'aplicar tècniques específiques de desbiatjat (debiasing) en diferents fases del cicle de vida del desenvolupament del programari:



1. Tècniques de Pre-processat (Abans de l'entrenament)

- Reequilibri de dades: Augmentar artificialment la mostra del grup infrarepresentat utilitzant tècniques de sobremostreig estadístic.
- Eliminació d'atributs i correlacions: No n'hi ha prou amb eliminar la columna "gènere" del dataset (ja que la IA pot deduir el gènere mitjançant variables correlacionades com les aficions, revistes subscrites o el tipus d'estudis). S'han d'aplicar anàlisis de components per a eliminar les relacions de dependència indirectes d'aquestes variables.

2. Tècniques d'In-processat (Durant l'entrenament)

- Inclusió de restriccions d'equitat en la funció de pèrdua: En lloc de demanar-li a la IA només que maximitze la precisió, se li afeg una penalització matemàtica si les seues decisions difereixen significativament entre homes i dones. L'algorisme es veu obligat a buscar una solució que siga precisa, però alhora equitativa.

3. Tècniques de Post-processat (Després de l'entrenament)

- Ajustament de llindars de classificació: Si un model assigna una puntuació de probabilitat de concessió d'un crèdit, es poden establir llindars (thresholds) diferenciats per a assegurar que el percentatge d'aprovació siga el mateix en tots els gèneres (mètrica de Paritat Demogràfica), corregint la desviació de sortida de l'algorisme abans de fer-lo servir.