


Curs d'especialització: **Intel·ligència Artificial i Big Data**
Família Professional: **Informàtica i Comunicacions**
Grau: **Superior**
Durada: **600 hores en un curs de 30 setmanes**

Mòdul 5072 - Sistemes d'aprenentatge automàtic



Índex

- [Tema 1. Classificació de la Intel·ligència Artificial: forta i feble](#)
- [Tema 2. Machine Learning \(Aprentatge Automàtic\)](#)
- [Tema 3. Algorismes aplicats a l'aprenentatge supervisat i optimització del model](#)
- [Tema 4. Aprentatge no supervisat i models computacionals de xarxes neuronals](#)
- [Tema 5. Valoració dels resultats obtinguts amb aprenentatge automàtic](#)

Tema 1. Classificació de la Intel·ligència Artificial: forta i feble



1. Intel·ligència Artificial Dèbil
2. Intel·ligència Artificial Forta
3. Comparació entre IA feble i IA forta
4. Idees clau per a recordar

La Intel·ligència Artificial (IA) és una branca de la informàtica que desenvolupa sistemes capaços de realitzar tasques que normalment requereixen intel·ligència humana, com aprendre, raonar, reconèixer imatges, comprendre el llenguatge o prendre decisions.

Hi ha dos grans tipus d'IA.

- Intel·ligència Artificial Dèbil (o IA estreta).
- Intel·ligència Artificial Forta (o IA general).

La principal diferència és que la IA feble està dissenyada per fer tasques específiques, mentre que la IA forta seria capaç de pensar i aprendre com una persona.

1. Intel·ligència Artificial Dèbil

Què és?

La IA feble és un tipus d'intel·ligència artificial creada per fer una o diverses tasques concretes. No comprèn realment el que fa ni té consciència o emocions.

És l'única IA que existeix actualment i és present en molts aspectes de la nostra vida quotidiana.

Característiques

- Està especialitzada en tasques concretes.
- Aprèn mitjançant dades i algorismes.
- No té consciència ni raonament propi.
- Funciona dins dels límits per als quals ha estat dissenyada.
- Pot ser molt precisa i ràpida en el seu camp d'actuació.

Aplicacions

La IA feble s'utilitza en nombrosos àmbits:

- Assistents virtuals (ChatGPT, Siri, Alexa o Google Assistant).
- Sistemes de recomanació (Netflix, Spotify, YouTube o Amazon).
- Reconeixement facial i de veu.
- Traducció automàtica.
- Vehicles amb sistemes d'assistència a la conducció.
- Diagnòstic mèdic mitjançant anàlisis d'imatges.
- Detecció de frau bancari.
- Robots industrials.

Avantatges

- Automatitza tasques repetitives.

- Redueix errors humans.
- Treballa de manera ràpida i contínua.
- Augmenta la productivitat.
- Ajuda a la presa de decisions.
- Facilita serveis personalitzats.

Inconvenients

- Només podeu realitzar tasques per a les quals ha estat entrenada.
- Depèn de la qualitat de les dades.
- Poden cometre errors inesperats.
- Poden generar biaixos si les dades estan esbiaixades.
- Substitueix algunes feines repetitives.
- Planteja problemes relacionats amb la privadesa.

Possibilitats

Actualment la IA feble permet:

- Millorar l'atenció sanitària.
- Optimitzar el transport.
- Personalitzar l'educació.
- Automatitzar processos industrials.
- Millorar l'atenció al client.
- Facilitar la investigació científica.

En el futur seguirà evolucionant, essent cada cop més precisa i útil.

2. Intel·ligència Artificial Forta

Què és?

La IA forta, també anomenada Intel·ligència Artificial General (AGI), seria una intel·ligència capaç de comprendre, aprendre i raonar igual que un ésser humà.

Podria enfrontar-se a qualsevol problema sense haver estat programada específicament per fer-ho.

Actualment no existeix. És un objectiu de recerca i un tema de debat científic.

Característiques

- Comprendria qualsevol tipus d'informació.
- Aprendria de manera autònoma.

- Podria adaptar-se a situacions noves.
- Resoldria problemes molt diversos.
- Transferiria coneixements entre diferents tasques.
- El seu raonament seria semblant a l'humà.

Possibles aplicacions

Si arribés a desenvolupar-se, podria utilitzar-se per a:

- Investigació científica.
- Descobriment de nous medicaments.
- Educació completament personalitzada.
- Gestió de grans infraestructures.
- Exploració espacial.
- Resolució de problemes complexos relacionats amb el clima o l'energia.
- Assistència mèdica avançada.

Avantatges

- Gran capacitat d'aprenentatge.
- Adaptació a qualsevol entorn.
- Resolució de problemes molt complexos.
- Major suport a la investigació científica.
- Automatització de treballs intel·lectuals.

Inconvenients

- Riscos ètics i legals.
- Possible substitució de nombroses ocupacions.
- Dificultat per controlar les decisions.
- Possible ús militar o amb fins maliciosos.
- Necessitat de regulació internacional.

Possibilitats

Tot i que encara no existeix, podria:

- Treballar amb les persones.
- Resoldre malalties complexes.
- Millorar la productivitat mundial.
- Dissenyar noves tecnologies.

- Ajudar a fer front a problemes globals.

Això no obstant, el seu desenvolupament requerirà normes per a garantir un ús segur i responsable.

3. Comparació entre IA feble i IA forta


IA feble	IA forta
Existeix actualment.	Encara no existeix.
Realitza tasques específiques.	Podria realitzar qualsevol tasca intel·lectual.
No comprèn realment la informació.	Comprendria i raonaria com un ésser humà.
Està limitada al seu entrenament.	Aprendria de manera autònoma.
S'utilitza diàriament.	És un objectiu de recerca.

4. Idees clau per a recordar

- **La IA feble** és la que utilitzem hui dia i està especialitzada en tasques concretes.
- **La IA forta** seria capaç d'aprendre i raonar com una persona, però encara no existeix.
- La intel·ligència artificial ofereix grans beneficis en medicina, educació, indústria i transport, encara que també planteja reptes relacionats amb l'ètica, l'ocupació i la privadesa.
- El desenvolupament responsable de la IA serà fonamental per aprofitar-ne els avantatges i minimitzar-ne els riscos.

Nota important: Tot i que eines com ChatGPT són molt avançades, pertanyen a la IA feble. Poden fer moltes tasques diferents, però no tenen consciència, comprensió humana ni intel·ligència general com la que s'atribueix a una IA forta.

Tema 2. Machine Learning (Aprentatge Automàtic)



1. Classificació de sistemes d'aprenentatge automàtic
2. Principals tècniques per desenvolupar aprenentatge automàtic
3. Algorismes o models aplicats a l'aprenentatge automàtic
4. Altres algorismes relacionats
5. Funcionament essencial del Machine Learning
6. Llenguatges de programació
7. Biblioteques i Frameworks
8. Aplicacions del Machine Learning

El Machine Learning (ML) o Aprenentatge Automàtic és una branca de la Intel·ligència Artificial que permet als sistemes aprendre a partir de dades i millorar-ne el rendiment sense necessitat de ser programats explícitament per a cada tasca.

En lloc de seguir instruccions detallades, els algoritmes de Machine Learning identifiquen patrons en les dades i utilitzen aquests patrons per fer prediccions o prendre decisions.

Actualment, el Machine Learning està present en nombrosos serveis que utilitzem diàriament, com ara recomanacions de pel·lícules, assistents virtuals, filtres de correu no desitjat o reconeixement facial.

1. Classificació de sistemes d'aprenentatge automàtic

Els sistemes de Machine Learning es poden classificar segons la manera com aprenen de les dades.

1.1 Aprenentatge Supervisat

En aquest tipus d'aprenentatge, l'algoritme rep dades d'entrenament que ja inclouen la resposta correcta.

L'objectiu és aprendre la relació entre les dades d'entrada i els resultats esperats.

Característiques

- Utilitza dades etiquetades.
- Requereix exemples correctes per entrenar el model.
- Permet fer prediccions futures.

Exemples

- Classificar correus electrònics com a correu brossa o no.
- Predir el preu d'un habitatge.
- Reconeixement de les imatges.

Avantatges

- Alta precisió quan hi ha suficients dades.
- Fàcil avaluació de resultats.

Inconvenients

- Necessiteu grans quantitats de dades etiquetades.
- L'etiquetatge pot ser costós i lent.

1.2 Aprenentatge No Supervisat

L'algorisme treballa amb dades que no tenen etiquetes ni respostes conegudes.

El seu objectiu és trobar patrons, relacions o agrupacions ocultes en les dades.

Característiques

- Utilitza dades sense classificar.
- Descobreix estructures internes de manera autònoma.
- Permet trobar informació desconeguda.

Exemples

- Segmentació de clients.
- Agrupació de productes similars.
- Detecció de comportaments anòmals.

Avantatges

- No cal etiquetar dades.
- Podeu descobrir relacions inesperades.

Inconvenients

- Resultats més difícils d'interpretar.
- Menys control sobre l'aprenentatge.

2. Principals tècniques per desenvolupar aprenentatge automàtic

2.1 Xarxes Neuronals Artificials


Una Xarxa Neuronal Artificial (Artificial Neural Network) és un model matemàtic i computacional inspirat en el funcionament del cervell humà. És la tecnologia clau que hi ha darrere dels grans avenços de la Intel·ligència Artificial actual, com el reconeixement de veu, la generació d'imatges o els cotxes autònoms.

A la pràctica, és un sistema informàtic dissenyat per aprendre a partir de l'experiència i les dades, en lloc de seguir instruccions o regles fixes programades per un humà.

Parlem de l'analogia biològica, de la mateixa manera que el nostre cervell està format per milers de milions de neurones connectades entre si, una xarxa artificial es compon de nodes (neurones artificials) organitzats en diferents nivells o capes:

- Capa d'Entrada (Input Layer): És on la xarxa rep les dades inicials. Per exemple, els píxels d'una fotografia d'un gat.
- Capes Ocultes (Hidden Layers): Són capes intermèdies on passa la "màgia". Cada capa processa la informació de l'anterior i en detecta patrons. Una capa pot detectar línies, la següent formes geomètriques (cercles, triangles) i la següent estructures completes (ulls, orelles).
- Capa d'eixida (Output Layer): Mostra el resultat final de la predicció. Per exemple, la confirmació: "Això és un gat amb un 95% de probabilitat".

Xarxa Neuronal Artificial (Feedforward)



El procés d'aprenentatge (com "pensar"?). Les connexions entre les neurones artificials tenen un valor numèric anomenat pes (weight), que determina la importància que té una dada per a la següent neurona.

Tenim també l'error inicial: Al principi, la xarxa té peses completament aleatòries, així que falla constantment (pot confondre un gat amb un cotxe).

Correcció d'errors: Quan s'equivoca, un algorisme intern calcula la diferència entre el que ha dit la xarxa i la realitat.

Ajustament (Retropropagació): El sistema fa un camí de tornada (backpropagation) i ajusta lleugerament totes les peses de les connexions per no tornar a cometre el mateix error.

Si repeteixes aquest procés milions de vegades amb milers d'exemples, la xarxa aprèn a encertar quasi sempre.

Quina relació tenen amb el "Deep Learning"? Segurament hauràs sentit el terme Deep Learning (Aprenentatge Profund). Aquest concepte es refereix, precisament, a l'ús de xarxes neuronals artificials que tenen moltes capes ocultes (xarxes "profundes"). Com més capes té una xarxa, més capaç és de resoldre problemes abstractes i complexos.

Aplicacions

- Reconeixement de veu.
- Visió artificial.

- Traducció automàtica.
- Vehicles autònoms.

Avantatges

- Gran capacitat per aprendre patrons complexos.
- Molt eficaços amb grans quantitats de dades.

Inconvenients

- Requereixen molta potència de càlcul.
- El funcionament pot ser difícil d'interpretar.

2.2 Aprenentatge Inductiu

L'Aprenentatge Inductiu és un mètode de coneixement que consisteix a extreure una conclusió general a partir de l'observació de casos particulars o d'exemples concrets.

Dins del món de la intel·ligència artificial i el Machine Learning, gairebé tot el que anomenem "aprenentatge automàtic" es basa en aquest principi. El sistema no rep lleis universals programades per un humà, sinó que analitza milers de dades per descobrir per si mateix les regles subjacents.

Per a veure clar com funciona la inducció, el millor és comparar-la amb el seu oposat, la deducció. El mètode deductiu (De la llei al cas), parteix d'una norma general ja coneguda o llei: "Tots els humans són mortals"

-> Cas: "Xavi és humà" -> Conclusió deductiva: "Xavi és mortal". (Risc d'error: 0%).

Mètode Inductiu (Del cas a la llei): Es parteix de fets observats. Casos: "El corb número 1 és negre", "El corb número 2 és negre", "El corb número 3 és negre"... -> Conclusió inductiva: "Tots els corbs són negres".

Com s'aplica en la Intel·ligència Artificial? En les Xarxes Neuronals, l'aprenentatge és purament inductiu. En lloc de donar-li a l'ordinador una llista de normes lògiques com "si té orelles punxegudes i bigotis, és un gat", el procés inductiu funciona així:

- Entrenament: Li mostres a l'algorisme 10.000 fotos de gats i 10.000 fotos de gossos.
- Abstracció de patrons: El sistema observa característiques comunes dels gats que es repeteixen (formes d'ulls, siluetes).
- Generalització: Crea una hipòtesi o model intern per definir què és un gat.
- Predicció: Quan li ensenyes una foto completament nova, aplica aquesta "llei general" que ha après per endevinar quin animal és.

El gran perill de la inducció: El biaix i la falsa generalització. Com que les conclusions inductives es basen en l'observació de fets passats, mai són 100% segures, sinó probables. Si el sistema només veu dades incompletes o parcials, arribarà a conclusions falses (el que en IA anomenem biaix): Si entrenes un sistema de selecció de personal de forma inductiva

amb l'historial de contractacions d'una empresa on els últims 20 anys només s'han contractat homes per a llocs directius, l'algorisme arribarà a la conclusió general que "els homes són millors directius". La màquina no té moral; només troba un patró estadístic en les dades particulars que li has donat. Per això és tan crític controlar la qualitat i la diversitat de les dades d'entrenament.

Exemple

Si moltes persones que compren un producte també en compren un altre, el sistema aprèn aquesta relació.

2.3 Raonament Basat en Casos


El Raonament Basat en Casos (CBR, per les seves sigles en anglès Case-Based Reasoning) és un paradigma d'intel·ligència artificial i aprenentatge automàtic que resol problemes nous adaptant solucions que es van utilitzar per resoldre problemes passats similars.

A diferència dels models clàssics de machine learning que intenten crear regles generals o fórmules matemàtiques a partir d'un gran conjunt de dades, el CBR actua de manera molt semblant als humans: utilitza la memòria i l'experiència directa acumulada en una base de dades de "casos" per trobar una drecera cap a la solució.

Un exemple quotidià seria un mecànic que repara un cotxe detectant exactament els mateixos símptomes que va veure en un vehicle la setmana anterior.

El Cicle dels 4 Passos (Les 4 "R"). Qualsevol sistema de Raonament Basat en Casos opera mitjançant un cicle continu dividit en quatre etapes clau:

1. Recuperar (Retrieve): Davant d'un problema nou, el sistema busca a la seva base de dades aquells casos anteriors que s'hi assemblin més.
2. Reutilitzar (Reuse): El sistema agafa la solució del cas antic i la lliga al nou problema. Si és necessari, fa les adaptacions pertinents perquè quadri amb el context actual.
3. Revisar (Review): Es posa a prova la solució proposada al món real o mitjançant simulacions per comprovar si funciona correctament i es corregeixen els errors si cal.
4. Retenir (Retain): Una vegada el problema s'ha resolt amb èxit, la lliçó apresca es guarda com un nou cas a la base de dades, permetent que el sistema "aprenca" de l'experiència.



Exemple

Un sistema mèdic pot diagnosticar una malaltia comparant el cas actual amb diagnòstics anteriors.

Avantatges

- Aprèn mitjançant experiències prèvies.
- Fàcil d'actualitzar amb casos nous.

2.4 Altres tècniques

Aprenentatge profund (Deep Learning)

És una evolució de les xarxes neuronals que utilitza múltiples capes per processar informació complexa.

Algorismes Genètics

S'inspiren en l'evolució biològica per trobar solucions òptimes mitjançant processos semblants a la selecció natural.

Sistemes Difusos (Fuzzy Logic)


La lògica difusa (o fuzzy logic) és una forma de lògica polivalent que permet treballar amb graus de veritat parcials entre el 0 (totalment fals) i l'1 (totalment cert). A diferència de la lògica clàssica de computadors, que només entén de binari o valors absoluts (blanc o negre, 0 o 1), la lògica difusa s'assembla al raonament humà.

3. Algorismes o models aplicats a l'aprenentatge automàtic

3.1 Algorismes de Classificació

Els algorismes de classificació són models de Machine Learning supervisat que s'utilitzen per predir una etiqueta o categoria discreta per a una dada d'entrada. A diferència de la

regressió, que prediu un número continu (com el preu d'una casa), la classificació respon a preguntes categòriques com "aquest correu és spam o no?" o "quina malaltia té aquest pacient?".



A l'etapa d'avaluació de la classificació no s'utilitzen mètriques de distància com l'MSE de la regressió, sinó eines basades en l'encert d'etiquetes:

Matriu de Confusió: Una taula que mostra els encerts i errors del model creuant la realitat amb la predicció (Veritables Positius, Falsos Positius, Veritables Negatius i Falsos Negatius).

Accuracy (Exactitud): El percentatge total de prediccions correctes sobre el total de casos. Precision i Recall: Mètriques crítiques quan les dades estan desequilibrades (per exemple, si només 1 de cada 1.000 transaccions és un frau bancari).

La configuració pràctica d'aquests models i les seves mètriques es realitza de forma estàndard mitjançant l'apartat de scikit-learn Supervised Learning (és la secció específica de la biblioteca scikit-learn, una de les eines més importants i utilitzades en Python per a la ciència de dades, que conté tots els algorismes i eines destinats a l'aprenentatge supervisat).

Exemples: Spam o no spam, Malalt o sa, client potencial o no potencial...

Aplicacions: Medicina, seguretat informàtica, màrqueting...

3.2 Algorismes de Detecció d'Anomalies

Els algorismes de detecció d'anomalies s'encarreguen d'identificar patrons, esdeveniments o observacions estranyes que no es comporten com la resta de dades. Aquests elements inusuals s'anomenen anomalies o valors atípics (outliers).

Aplicacions


- Detecció de fraus bancaris.
- Ciberseguretat.
- Control de qualitat industrial.

Exemple

- Detectar moviments sospitosos en un compte bancari.

3.3 Algorismes de Regressió

Prediuen valors numèrics continus. Els algorismes de regressió són models de Machine Learning supervisat que s'utilitzen per predir un valor numèric continu. A diferència de la classificació (que decideix entre etiquetes com "gat" o "gos"), la regressió respon a preguntes quantitatives com "quant costarà?" o "quants usuaris vindran?".



Aplicacions


- Predicció de preus.
- Pronòstics meteorològics.
- Estimació de vendes.

Exemple

Calculeu el preu futur d'un habitatge.

3.4 Algorismes de Clustering

Els algorismes de clustering (o d'agrupament) són models de Machine Learning no supervisat. A diferència de la regressió, ací les dades no tenen etiquetes ni respostes correctes. El seu objectiu és explorar les dades per a agrupar-les en conjunts (clústers), de manera que els elements d'un mateix grup siguin molt similars entre si i molt diferents dels altres grups.



Aplicacions

- Segmentació de clients.
- Organització de documents.
- Anàlisi de mercats.

Exemple

Crear grups de consumidors segons els hàbits de compra.

3.5 Algorismes de Reforç de l'Aprenentatge

L'aprenentatge per reforç (Reinforcement Learning o RL) és el tercer gran paradigma del Machine Learning, juntament amb el supervisat i el no supervisat. No es basa en un conjunt de dades estàtic, sinó en el concepte d'aprendre fent. Un agent (l'algorisme) aprèn a prendre decisions dins d'un entorn desconegut mitjançant un sistema de recompenses (positives) i penalitzacions (negatives) obtingudes per assaig i error.

Conceptes clau del Reforç:

- **Agent:** L'entitat que pren les decisions (per exemple, el programari d'un cotxe autònom).
- **Entorn (Environment):** El món virtual o real on interactua l'agent (la carretera i el trànsit).
- **Estat (State):** La situació actual en la qual es troba l'entorn (la velocitat del cotxe i la distància amb els altres vehicles).
- **Acció:** La decisió que pren l'agent en cada moment (frenar, accelerar o girar).
- **Recompensa (Reward):** El retorn que rep l'agent. Si condueix bé rep punts positius; si xoca, en rep de negatius. L'objectiu de l'algorisme és maximitzar la recompensa total a llarg termini.

Aplicacions

- Robots autònoms.
- Videojocs.
- Vehicles intel·ligents.

Exemple

Un robot aprèn a caminar corregint els errors.

3.6 Arbres i Regles de Decisió

Utilitzen una estructura semblant a un arbre per prendre decisions mitjançant preguntes successives.

Els **arbres de decisió** i les **regles de decisió** són models d'aprenentatge automàtic supervisat que destaquen per ser extremadament visius i fàcils d'entendre per als humans. S'utilitzen tant per a problemes de **classificació** (per exemple, saber si un client pagarà un crèdit) com de **regressió** (estimar el preu d'un cotxe).

Avantatges

Fàcil interpretació. Bona capacitat d'explicació.

Exemple


Concedir o no un préstec segons ingressos, edat i situació laboral.

4. Altres algorismes relacionats

Màquines de Vectors de Suport (SVM)

Utilitzades per a classificació i reconeixement de patrons. Són algorismes de Machine Learning supervisat molt potents. S'utilitzen principalment per a problemes de **classificació**, tot i que també es poden adaptar per a tasques de regressió.


L'objectiu principal d'una SVM és trobar la millor línia de divisió possible (anomenada **hiperplà**) per a separar les dades de diferents categories amb el marge més gran possible.



K-Nearest Neighbors (KNN)

(*K-Veïns Més Propers*) és un dels algorismes de Machine Learning supervisat més senzills i intuïtius. S'utilitza principalment per a problemes de classificació (assignar una categoria a una dada), tot i que també es pot aplicar a tasques de regressió.


A diferència de la majoria d'algorismes, el KNN és un model **aproximat o gandul** (*lazy learner*) perquè no passa per una fase d'entrenament matemàtic per a crear una fórmula. Simplement es guarda a la memòria totes les dades del passat i espera a rebre una dada nova per fer els càlculs de proximitat.



Random Forest

Combina múltiples arbres de decisió per millorar-ne la precisió.

La seva filosofia és senzilla: en lloc de confiar en la decisió d'un sol arbre de decisió (que pot equivocar-se fàcilment), combina les prediccions de desenes o centenars d'arbres de decisió diferents per obtenir un resultat final per consens. Això es coneix com un model de conjunt (Ensemble Method).



Naive Bayes

El Naive Bayes (o Bayes Ingenu) és un algorisme de Machine Learning supervisat que s'utilitza principalment per a problemes de classificació. Es basa en el cèlebre Teorema de Bayes de la teoria de la probabilitat i és especialment famós per la extrema rapidesa i eficiència en el processament de text.

L'algorisme s'anomena "Ingenu" (Naive) perquè assumeix una condició molt radical: considera que totes les característiques d'una dada són completament independents entre si.

Per exemple, si una fruita és roja, rodona i fa 8 cm, l'algorisme assumeix que el fet de ser roja no té res a veure amb el fet de ser rodona, la qual cosa científicament no sempre és veritat, però a la pràctica funciona sorprenentment bé.

L'aplicació històrica i més coneguda d'aquest algorisme és la detecció de correu brossa (Spam).

5. Funcionament essencial del Machine Learning

El funcionament essencial del Machine Learning es redueix exactament a tres etapes abstractes i cícliques. Aquestes tres etapes macroscòpiques són:

1. La Representació (L'Entrada): És la fase on es defineix el model i se li subministren les dades. Consisteix a transformar la realitat en un espai matemàtic que l'ordinador puga entendre.

Què inclou: La recollida de dades, la neteja i la tria de l'algorisme (per exemple, decidir si farem servir un Random Forest, una SVM o un Naive Bayes).

L'objectiu: Crear l'estructura base on viuran les dades.

2. L'Avaluació (El Càlcul de l'Error): És el criteri que utilitza l'ordinador per saber si ho està fent bé o malament. Una màquina no sap què és "fer-ho bé" a menys que li donem una funció matemàtica per mesurar-ho.

Què inclou: L'ús d'una funció de pèrdua (Loss Function) o d'avaluació. Per exemple, en una Regressió, mesura la distància entre el preu predit de la casa i el preu real.

L'objectiu: Quantificar l'error exacte que comet el model en cada intent.

3. L'Optimització (L'Ajust i Aprenentatge): És el motor d'aprenentatge pròpiament dit. Un cop l'etapa d'avaluació diu "t'has equivocat per un 20%", l'algorisme d'optimització busca la manera de moure els paràmetres interns del model per reduir aquest error en la següent iteració.

Què inclou: Algorismes matemàtics de cerca com el Descens del Gradient.

L'objectiu: Modificar el model de forma intel·ligent fins a trobar la combinació de paràmetres que minimitzi l'error al màxim.

6. Llenguatges de programació

Python: És el llenguatge més utilitzat gràcies a la seua simplicitat i gran quantitat de biblioteques.

R: Especialitzat en estadística i anàlisi de dades.

7. Biblioteques i Frameworks

Scikit-learn: Biblioteca de Python per a algorismes clàssics de Machine Learning.

TensorFlow: Desenvolupada per Google per a xarxes neuronals i Deep Learning.

PyTorch: Molt utilitzada en investigació i desenvolupament d'IA.

Keras: Facilita la creació de xarxes neuronals.

Plataformes Google Colab: Permet executar projectes de Machine Learning des del navegador.

Microsoft Azure Machine Learning: Servei al núvol per desenvolupar models intel·ligents.

Amazon SageMaker: Plataforma de Machine Learning d'Amazon

8. Aplicacions del Machine Learning

El Machine Learning té aplicacions en nombrosos sectors.

Medicina

- Diagnòstic assistit.
- Detecció primerenca de malalties.
- Anàlisi d'imatges mèdiques.

Finances

- Detecció de frau.
- Predicció de riscos.
- Gestió de les inversions.

Comerç Electrònic

- Recomanació de productes.
- Anàlisi de preferències de clients.

Transport

- Vehicles autònoms.
- Optimització de rutes.

Educació

- Sistemes d'aprenentatge personalitzats.
- Correcció automàtica d'exercicis.

Seguretat

- Reconeixement facial.
- Detecció d'intrusions.
- Ciberseguretat.

Indústria

- Manteniment predictiu.
- Automatització de processos.
- Control de qualitat.

Entreteniment

- Recomanació de pel·lícules i música.
- Videojocs intel·ligents.

Tema 3. Algorismes aplicats a l'aprenentatge supervisat i optimització del model



1. Elements i eines d'aprenentatge supervisat
2. Dades etiquetades
3. Variables d'entrada (Input Data) i etiquetes d'eixida
4. Plataformes d'aprenentatge automàtic supervisat
5. Fases de l'aprenentatge automàtic

L'aprenentatge supervisat (Supervised Learning) és una branca del Machine Learning on un model aprèn utilitzant dades prèviament etiquetades. Durant l'entrenament, l'algorisme coneix quina és la resposta correcta i aprèn la relació entre les dades d'entrada i l'eixida esperada.

El seu objectiu és crear un model capaç de fer prediccions precises sobre dades noves.

Exemples:

- Detectar si un correu és spam o no.
- Predir el preu d'un habitatge.
- Reconèixer objectes en una imatge.
- Diagnosticar malalties a partir de proves mèdiques.

1. Elements i eines d'aprenentatge supervisat

Per a desenvolupar un sistema d'aprenentatge supervisat són necessaris diversos elements.

Elements principals

- **Dades.** Són la base de l'aprenentatge.

- **Algorisme d'aprenentatge.** És el mètode matemàtic que utilitzarà l'ordinador per a aprendre la relació entre entrades i eixides.

Exemples:

- Regressió lineal.
- Arbres de decisió.
- Xarxes neuronals.
- Màquines de suport vectorial (SVM).
- Random Forest.
- K-Nearest Neighbors (KNN).

- **Model.** És el resultat de l'entrenament. Una vegada es té el model, es pot utilitzar per a fer prediccions sobre dades noves.

- **Funció de pèrdua (Loss Function).** Mesura quant s'equivoca el model.

L'objectiu de l'entrenament és minimitzar aquest error.

Algunes són:

- Precisió (Accuracy).
- Precisió positiva (Precision).
- Sensibilitat (Recall).
- F1-Score.

- Error quadràtic mitjà (MSE).
- MAE (Error absolut mitjà).

2. Dades etiquetades

Què són? Són dades que inclouen la resposta correcta.

Cada exemple té informació d'entrada i el resultat esperat. Per exemple, una imatge d'un gos i la etiqueta gos o un Email Spam amb l'etiqueta spam.

L'algorisme aprèn observant milers o milions d'exemples semblants.

Avantatges

- Aprenentatge molt precís.
- Fàcil avaluació del rendiment.
- Bons resultats quan hi ha bastants dades.

Inconvenients

- Etiquetar dades requereix temps.
- Pot ser costós.
- De vegades és difícil aconseguir dades de qualitat.

3. Variables d'entrada (Input Data) i etiquetes d'eixida

Les variables d'entrada (en anglès, input data o features) són les característiques, atributs o peces d'informació que es col·loquen dins d'un model de machine learning perquè aquest pugui fer una predicció.

En termes matemàtics o estadístics, se les coneix com a variables independents (normalment representades amb la lletra X).

Exemples:

Predicció del preu d'una casa: Variables d'entrada: Els metres quadrats, el nombre d'habitacions, l'any de construcció i el codi postal.

Filtre de correu brossa: Variables d'entrada: Les paraules del text, l'adreça del remitent i el nombre de fitxers adjunts.

Cotxe autònom: Variables d'entrada: Les imatges de les càmeres en temps real, la distància detectada pels sensors i la velocitat actual.

Tipus comuns de variables d'entrada. Les teues dades d'entrada poden ser de diferents formats segons el problema:

- Numèriques: Edat, preu, temperatura, alçada.
- Categories: Gènere (Masculí/Femení), colors (Roig/Blau/Verd), marques de cotxes.
- Text en brut: Tuits, ressenyes de clients, articles científics. Multimèdia: Píxels d'una

imatge, freqüències d'un àudio o fotogrames d'un vídeo.

Regla d'or: La qualitat de l'entrada ho és tot. En machine learning existeix la frase "Garbage in, garbage out" (Si entra entra fem ix fem). Si les variables d'entrada són incorrectes, estan incompletes o tenen molt de soroll, el model farà males prediccions, per molt bo que siga l'algorisme.

Les etiquetes d'eixida (output labels o simplement targets/labels) són la resposta, el resultat o la predicció final que el model de machine learning ha de calcular a partir de les variables d'entrada.

Si les variables d'entrada (X) són les pistes del problema, l'etiqueta d'eixida (Y) és la solució de l'examen. En l'aprenentatge supervisat, durant l'entrenament ensenyes al model l'entrada i l'eixida correcta per a que aprenga la relació entre les dues.

Exemples concrets de variables d'eixida:

Segons el tipus de problema que vullgues resoldre, l'etiqueta d'eixida canvia de format:

- Classificació binària (dues opcions)
- Classificació múltiple (diverses opcions)

El doble paper de l'eixida: Entrenament vs. Predicció

L'etiqueta d'eixida es comporta de manera diferent segons el moment en què es troba el model:

- Durant l'entrenament: Tu ja saps l'eixida. Li dones al model l'entrada i l'eixida real. Si el model s'equivoca en la seua predicció, es compara amb l'etiqueta d'eixida real per corregir els errors (procés anomenat càlcul de la pèrdua o loss).
- Durant la predicció (Fase de test/producció): L'eixida és desconeguda. Li dones al model una entrada nova (per exemple, una foto que mai ha vist) i l'algorisme ha d'endevinar i generar l'etiqueta d'eixida correcta.

El problema del "biaix" en l'eixida. L'eixida del model mai serà millor que les etiquetes que vas utilitzar per entrenar-lo. Si etiquetes erròniament molts correus bons com a Spam, el model finalment farà una eixida defectuosa i bloquejarà correus importants dels teus usuaris.

4. Plataformes d'aprenentatge automàtic supervisat

Hi ha nombroses eines per desenvolupar models de Machine Learning. Plataformes més utilitzades:

- **Google Colab** Gratuït. Funciona des del navegador. Inclou GPU. Molt utilitzat per a aprenentatge. Jupyter Notebook Permet escriure codi i documentació. Molt utilitzat en ciència de dades.
- **TensorFlow**. Biblioteca desenvolupada per Google. Permet crear models complexos mitjançant xarxes neuronals.
- **PyTorch**. Desenvolupada per Meta. Molt utilitzada en investigació i Intel·ligència Artificial

avançada.

- **Scikit-learn.** Una de les biblioteques més utilitzades per a Machine Learning clàssic. Inclou algorismes com: Regressió. Classificació. Clústering. Arbres de decisió.

- **Microsoft Azure Machine Learning.** Plataforma al núvol per desenvolupar models empresarials.

- **Amazon SageMaker.** Servei d'AWS per entrenar i implementar models.

5. Fases de l'aprenentatge automàtic

Les fases de l'aprenentatge automàtic (Machine Learning) conformen el procés iteratiu utilitzat per transformar dades en brut en un model predictiu funcional.

El cicle de vida d'un projecte d'aprenentatge automàtic es divideix en les següents fases principals:

1. Definició de l'objectiu. La fase inicial consisteix a definir clarament el problema que es vol resoldre.

- Establir els objectius de negoci.
- Traduir-los en un problema mètric.
- Identificar el tipus d'algorisme necessari.

2. Recopilació de dades. Es busquen i es reuneixen totes les fonts d'informació disponibles per alimentar el sistema.

- Extreure dades de bases de dades.
- Recollir històrics d'interaccions d'usuaris.
- Assegurar un volum de dades suficient.

3. Preparació i neteja de dades. Aquesta sol ser la fase que consumeix més temps, ja que les dades reals acostumen a ser desordenades.

- Eliminar valors duplicats o erronis.
- Gestionar les dades absents.
- Normalitzar i transformar formats textuais o numèrics.

4. Enginyeria de característiques (Feature Engineering). Es seleccionen i es transformen les variables més rellevants per facilitar el treball de l'algorisme.

- Seleccionar els atributs de destí clau.
- Crear noves variables combinant-ne d'existents.
- Reduir el soroll prescindint d'informació irrellevant.

5. Selecció i entrenament del model. Es tria l'estructura matemàtica més adequada i s'ajusta utilitzant les dades preparades.

- Dividir les dades en conjunts d'entrenament i validació.


- Escollir l'algorisme (per exemple, classificació o regressió).
- Executar l'entrenament perquè la màquina aprengui patrons.

6. Avaluació i optimització. Es comprova el rendiment del model amb dades noves que el sistema no ha vist mai durant l'entrenament.

- Avaluar mètriques com la precisió o l'error.
- Ajustar els hiperparàmetres per millorar els resultats.
- Evitar problemes com el sobreajustament (overfitting).

7. Desplegament i monitoratge. El model es llança a producció perquè comence a fer prediccions en un entorn real.

- Integrar el model en l'aplicació final.
- Monitorar el rendiment continu amb usuaris reals.
- Reentrenar el model periòdicament amb dades noves.



Tema 4. Aprenentatge no supervisat i models computacionals de xarxes neuronals



1. Tècniques d'aprenentatge no supervisat
2. Algorismes d'aprenentatge no supervisat
3. Determinació d'elements de l'aprenentatge no supervisat
4. Plataformes d'aprenentatge automàtic no supervisat
5. Fases de l'aprenentatge automàtic no supervisat
6. Aplicació de models de xarxes neuronals
7. Com aprèn una xarxa neuronal
8. Xarxes neuronals artificials

L'aprenentatge no supervisat (Unsupervised Learning) és una branca del Machine Learning on l'algorisme aprèn a partir de dades que no estan etiquetades. És a dir, el sistema no coneix la resposta correcta, sinó que ha de descobrir per ell mateix patrons, relacions o grups dins de les dades.

A diferència de l'aprenentatge supervisat, ací no es pretén predir una resposta coneguda sinó trobar estructures ocultes en la informació.

Exemples:

- Agrupar clients segons els hàbits de compra.
- Detectar comportaments anòmals en una xarxa informàtica.
- Organitzar fotografies similars automàticament.
- Analitzar grans quantitats d'informació científica.

1. Tècniques d'aprenentatge no supervisat

Les tècniques d'aprenentatge no supervisat permeten descobrir informació útil sense necessitat de disposar de dades etiquetades.

Les principals són:

1.1 Agrupació (Clustering)

L'agrupació o clustering és la tècnica principal de l'aprenentatge no supervisat. El seu objectiu és dividir un conjunt de dades en grups (clústers) de manera que les dades del mateix grup siguin molt similars entre elles i molt diferents de les dels altres grups, sense utilitzar etiquetes prèvies.

Les tècniques d'agrupació més utilitzades en el món real es classifiquen en diferents tipus:

1. Agrupació basada en particions (***K-Means***). És l'algorisme més popular i utilitzat per la seua simplicitat i rapidesa.

Funcionament: Divideix les dades en un nombre K de grups definit prèviament per l'usuari. Ubica uns punts centrals (centroïdes) i assigna cada dada al centroïde més proper, redibuixant els centres fins que no canvien.

Cas d'ús típic: Segmentació de clients d'una empresa segons el seu patró de compra.

2. Agrupació jeràrquica (***Hierarchical Clustering***). Crea una estructura en forma d'arbre (anomenada dendrograma) per mostrar com es relacionen els grups a diferents nivells de proximitat.

Funcionament: Pot ser aglomeratiu (comença amb cada dada com un grup individual i els va unint) o divisiu (comença amb totes les dades en un sol bloc i les va separant). No requereix definir el nombre de grups a l'inici.

Cas d'ús típic: Construcció de taxonomies o arbres genealògics de components o espècies biològiques.

3. Agrupació basada en la densitat (***DBSCAN***). Troba els grups basant-se en la concentració

de punts a l'espai.

Funcionament: Agrupa les regions on hi ha una alta densitat de dades i aïlla els punts que queden molt separats de la resta. És ideal per a formes irregulars i és molt bo detectant soroll i valors atípics (outliers).

Cas d'ús típic: Detecció de zones de trànsit intens en mapes o identificació d'activitats fraudulent.

4. Agrupació basada en models de distribució (**GMM**). Assumeix que les dades provenen d'una barreja de diferents distribucions de probabilitat.

Funcionament: Els Gaussian Mixture Models (GMM) assignen a cada dada una probabilitat de pertànyer a un grup, en lloc d'una decisió absoluta (agrupació difusa o soft clustering).


Cas d'ús típic: Modelat de senyals d'àudio o reconeixement de veu.

1.2 Reducció de dimensió: Molts conjunts de dades contenen centenars o milers de variables.

La reducció de dimensió consisteix a disminuir el nombre de variables conservant la quantitat més gran possible d'informació.

Aquesta tècnica és essencial per evitar la "maledicció de la dimensionalitat". La maledicció de la dimensionalitat (curse of dimensionality) fa referència als problemes, errors i complicacions que apareixen quan analitzem o entrenem models de Machine Learning amb conjunts de dades que tenen un nombre molt elevat de variables (dimensions).

També aconseguirem accelerar els entrenaments dels models i poder visualitzar dades complexes en gràfics de 2D o 3D.



Les tècniques més utilitzades es divideixen en mètodes lineals i no lineals:

- 1. **Mètodes Lineals**

PCA (Anàlisi de Components Principals / Principal Component Analysis): És la tècnica més famosa. Transforma les variables originals en un nou conjunt de variables incorrelacionades anomenades components principals. El primer component captura la màxima variància possible de les dades, el segon la següent, i així successivament.

Ideal per a Reduir columnes abans d'entrenar un algorisme de regressió o classificació.

LDA (Anàlisi Discriminant Lineal / Linear Discriminant Analysis): Tot i que sovint s'usa de forma supervisada, busca maximitzar la separabilitat entre classes projectant les dades en un espai de menor dimensió.

- 2. **Mètodes No Lineals (Manifold Learning)**. Quan les dades tenen relacions complexes que una línia recta o un pla no poden capturar, s'utilitzen tècniques no lineals:

t-SNE (t-Distributed Stochastic Neighbor Embedding): És una tècnica excel·lent per a la visualització de dades. Converteix les distàncies entre punts en probabilitats i intenta que els punts que estaven a prop en l'espai d'alta dimensió continuïn estant a prop en l'espai reduït (2D o 3D).

Ideal per a: Visualitzar agrupacions complexes de text, imatges o cèl·lules biològiques.

UMAP (Uniform Manifold Approximation and Projection): És una alternativa més moderna a t-SNE. És molt més ràpida amb grans volums de dades i conserva millor l'estructura global (la distància real entre grups allunyats), no només la local.

Avantatges de la reducció de dimensió:

- Redueix el temps de processament.
- Elimina informació redundant.
- Facilita la visualització de dades.
- Millora alguns models d'aprenentatge.

Detecció d'anomalies: Cerca identificar dades que es comporten de manera diferent de la resta.

Aplicacions:

- Detecció de frau bancari.
- Seguretat informàtica.
- Diagnòstic d'avaries.
- Control de qualitat industrial.

1.3 Regles d'associació: El seu objectiu és descobrir relacions, patrons o dependències ocultes entre elements d'un gran conjunt de dades.

Aquesta tècnica no busca predir una etiqueta ni agrupar usuaris, sinó respondre a la

pregunta: "Si passa el fenomen A, amb quina probabilitat passarà el fenomen B?"

L'exemple clàssic: L'anàlisi de la cistella de la compra

L'ús més conegut és als supermercats. L'algorisme analitza milers de tiquets de compra per trobar quins productes es compren junts.

Regla trobada: {Pa, Mantega} -> {Llet}

Significat: Els clients que compren pa i mantega, molt sovint també compren llet.

Les 3 mètriques clau per avaluar una regla. Per saber si una regla d'associació és realment bona o és una simple coincidència, s'utilitzen tres indicadors matemàtics:

Suport (Support): Indica com és de freqüent el conjunt d'elements en tot el dataset.

Fórmula: $(\text{Tiquets amb A i B}) / (\text{Total de tiquets})$.

Exemple: Un suport de 0,1 significa que el pa i la llet apareixen junts en el 10% de totes les compres.

Confiança (Confidence): Mesura la fiabilitat de la regla. Indica quantes vegades es compleix la predicció quan es dona la condició.

Fórmula: $(\text{Tiquets com A i B}) / (\text{Total de tiquets amb A})$.

Exemple: Una confiança de 0,7 significa que el 70% dels clients que han comprat pa, també han agafat llet.

Elevació (Lift): Mesura la força de la regla controlant com és de popular el producte B per si sol.

Si Lift > 1: Els elements estan associats positivament (comprar A augmenta la probabilitat de comprar B).

Si Lift = 1: Els elements són independents. No hi ha cap relació real.

Algorismes més utilitzats

Apriori: És l'algorisme històric i més famós. Utilitza una propietat que diu: "si un conjunt d'elements és freqüent, tots els seus subconjunts també ho han de ser". Genera les regles de forma iterativa, tot i que pot ser lent amb bases de dades gegants.

FP-Growth (Frequent Pattern Growth): Una alternativa molt més moderna i ràpida que Apriori. No necessita escanejar la base de dades sencer repetidament, sinó que comprimeix el dataset en una estructura d'arbre a la memòria.

Altres aplicacions del món real

Plataformes de Streaming: Recomanacions de pel·lícules ("Els usuaris que han vist la sèrie X també han vist la Y").

Disseny de botigues: Col·locar productes relacionats a prop (o molt lluny de forma estratègica) als prestatges d'un supermercat.

Diagnòstic mèdic: Identificar símptomes que solen aparèixer junts per predir malalties

complexes.

2. Algorismes d'aprenentatge no supervisat

Hi ha nombrosos algorismes per analitzar dades sense etiquetes.

Algorismes de clustering K-Means

És el mètode de clustering o agrupació més conegut i utilitzat en l'aprenentatge no supervisat. El seu objectiu principal és dividir un conjunt de dades en K grups (clústers) diferents basant-se en la distància geomètrica entre els punts.

Com funciona el K-Means pas a pas? L'algorisme funciona de manera iterativa seguint aquests quatre passos senzills:

[Pas 1: Triar K] →

[Pas 2: Assignar punts al centroide proper] → [

Pas 3: Recalculer centres] →

[Pas 4: Repetir]

Inicialització: Es tria el nombre K de grups que es volen crear. L'algorisme col·loca de manera aleatòria K punts a l'espai, anomenats centroides (els centres del grup).

Assignació: Cada punt de dades s'assigna al centroide que té més a prop (normalment utilitzant la distància euclidiana).

Actualització: Es calcula la mitjana de tots els punts que han caigut dins de cada grup i es mou el centroide exactament al centre d'aquesta nova mitjana.


Repetició: Els passos 2 i 3 es repeteixen una vegada i una altra fins que els centroides ja no es mouen de lloc o s'arriba al límit d'iteracions demanat.

Com es tria el nombre òptim de grups (K)? Com que K-Means necessita que li digues el nombre de grups abans de començar, s'utilitza una tècnica gràfica anomenada Mètode del Colze (Elbow Method). Es calcula la inèrcia (la suma de les distàncies al quadrat de cada punt al seu centroide) per a diferents valors de K (per exemple, de K=1 a K=10).


Es dibuixa un gràfic de línia. A mesura que puges la K, la inèrcia baixa.

El punt on la corba frena la seua caiguda en picat i es dibuixa una línia més plana (com un colze humà) indica el nombre ideal de grups.

K-MEANS: DIVISIÓ ESPACIAL (K = 3)



IDENTIFICACIÓ DEL PUNT DE TALL ÒPTIM



RESUM

- K-Means divideix l'espai en regions de Voronoi al voltant dels centroides.
- El nombre òptim de clusters (K) es pot trobar amb el mètode del colze (inèrcia) o amb el coeficient de silueta.

- ✗ Centroides inicials
- Centroides finals
- Punts no assignats (inicial)

- Cluster 1
- Cluster 2
- Cluster 3
- Frontera de decisió (Voronoi)

Avantatges

- Molt ràpid i eficient amb moltes dades.
- Fàcil d'entendre i d'implementar.
- Funciona molt bé si els grups són compactes i esfèrics.

Desavantatges

- Cal definir la K per avançat.
- Sensible als valors atípics (outliers).
- Falla si els grups tenen formes allargades o complexes.

Algorismes de reducció de dimensió PCA (Anàlisi de Components Principals)

L'Anàlisi de Components Principals (PCA) és l'algorisme lineal més utilitzat en l'aprenentatge no supervisat per reduir la dimensionalitat d'un conjunt de dades.

La seva funció és transformar moltes variables correlacionades en un nombre menor de variables noves i independents anomenades Components Principals (PCs), perdent la menor quantitat d'informació possible.

Com funciona el PCA pas a pas? El procés matemàtic del PCA se segueix de forma seqüencial:

[1. Normalitzar dades] →

[2. Matriu de covariància] →

[3. Vectors i valors propis] →

[4. Projectar dades]

Estandardització: Es transformen les dades perquè totes les variables tinguin mitjana 0 i variància 1. Això evita que les variables amb nombres més grans dominin l'algorisme de forma injusta.

Càlcul de la matriu de covariància: S'analitza com varien les columnes del conjunt de dades les unes respecte a les altres per identificar quines estan altament duplicades (correlacionades).

Càlcul d'Autovectors (Eigenvectors) i Autovalors (Eigenvalues): Els autovectors determinen les direccions dels nous eixos on les dades estan més esteses (components principals).

Els autovalors determinen la magnitud d'aquests eixos, és a dir, quanta informació (variància) reté cada component.

Projecció al nou espai: Es ordenen els components de més a menys importants. Es seleccionen els primers (per exemple, PC1 i PC2) i es projecten les dades originals sobre aquests nous eixos, eliminant la resta.

Propietats fonamentals dels Components Principals

PC1 (Primer Component Principal): És la línia recta que creua les dades capturant la màxima variància possible. És la direcció al llarg de la qual les dades estan més disperses.

PC2 (Segon Component Principal): És una línia completament perpendicular (ortogonal) al PC1.

Captura la major part de la variància restant. Com que són ortogonals, la correlació entre PC1 i PC2 és exactament zero.

Com es tria el nombre de components? (Gràfic de Sedimentació)


Per saber amb quants components ens hem de quedar (per exemple, reduir de 50 variables a 3), s'utilitza el Gràfic de Sedimentació (Scree Plot) o el càlcul de la Variància Explicada Acumulada:

Es dibuixa un gràfic de barres on cada barra és la variància que aporta cada PC.

El criteri habitual és seleccionar el nombre de components necessari fins a arribar a explicar entre el 80% i el 95% de la variància total de les dades originals.

ANÀLISI DE COMPONENTS PRINCIPALS (PCA)

PCA és una tècnica de reducció de dimensionalitat que transforma dades correlacionades en un nou conjunt de variables no correlacionades (components principals) que conserven la màxima variància possible.



3. Determinació d'elements de l'aprenentatge no supervisat

La determinació d'elements en l'aprenentatge no supervisat fa referència al procés crític de configurar, seleccionar i avaluar els paràmetres clau dels algorismes.

Com que no tenim etiquetes ni respostes correctes de referència, utilitzem criteris matemàtics interns i mètriques geomètriques per definir aquests elements de forma òptima.

A continuació es detallen els elements principals que s'han de determinar en les tres grans branques d'aquest tipus d'aprenentatge:

1. En l'Agrupació (Clustering): Determinació de clústers i mètriques

L'element més crític és decidir en quants grups (K) dividim les dades i com en mesurem la distància.

Determinació del nombre òptim de clústers (K):

- Mètode del Colze (Elbow Method):** Es calcula el WCSS (suma de quadrats dins del clúster). Es busca el punt d'inflexió on afegir més grups deixa d'aportar una reducció significativa de la variància.
- Anàlisi de Silueta (Silhouette Score):** Mesura com de similar és un punt al seu propi clúster en comparació amb els altres. El valor va de -1 a +1; un valor proper a +1 indica una configuració d'elements excel·lent.

Determinació de la mètrica de distància:

- Distància Euclidiana: La línia recta tradicional entre dos punts. Ideal per a espais continus i dades esfèriques.
- Distància de Manhattan: La suma de les distàncies absolutes (moviment en graella). Útil si les dades tenen moltes dimensions o distribucions asimètriques.

2. En reducció de dimensionalitat: Determinació de components clau

En algorismes com el PCA, l'element clau a determinar és el nombre de dimensions finals amb les quals ens quedarem.


- Criteri de la Variància Explicada Acumulada: Se seleccionen tants components principals com sigui necessari per retenir un percentatge fix de la informació original (generalment entre el 80% i el 95% de la variància total).
- Gràfic de Sedimentació (Scree Plot): Es visualitzen els autovalors (eigenvalues) de cada component. Es descarten tots aquells components que es troben per sota del punt on la corba s'estabilitza de forma horitzontal.

3. En Regles d'Associació: Determinació d'estratègies de filtratge

Per evitar generar milions de regles absurdes o evidents, determinem els llindars mínims d'acceptació de tres elements algebraics fonamentals:

- Llindar de Suport Mínim (Min Support): Defineix la freqüència mínima amb què un conjunt d'elements ha d'aparèixer en el dataset per ser considerat rellevant.
- Llindar de Confiança Mínima (Min Confidence): Fixa la fiabilitat mínima exigida a la regla (per exemple, exigir que es compleixi com a mínim el 60% de les vegades).
- Filtre d'Elevació (Lift Filter): Es descarten de forma fulminant totes aquelles regles amb un $Lift \leq 1$, ja que indiquen que la relació entre elements és purament aleatòria o independent.

Resum dels indicadors de validació



4. Plataformes d'aprenentatge automàtic no supervisat

Les plataformes per treballar amb aprenentatge automàtic no supervisat es divideixen principalment en:

- llibreries de codi obert per a desenvolupadors
- i entorns complets de línia de producció o No-Code per a empreses.

Com que l'aprenentatge no supervisat no requereix dades etiquetades prèviament, aquestes plataformes estan especialitzades en l'eficiència matemàtica per a l'agrupació, la detecció d'anomalies i la reducció de dimensions.

A continuació es detallen les plataformes i eines líders en el sector:

1. Llibreries i entorns de Codi Obert (Open Source). Són les eines fonamentals utilitzades per científics de dades per programar i experimentar directament.

scikit-learn: La llibreria reina de l'aprenentatge automàtic clàssic en Python. És la millor plataforma per a algorismes no supervisats tradicionals com K-Means, DBSCAN, PCA o Agrupació Jeràrquica.

PyTorch i TensorFlow: Són plataformes de Deep Learning profund. Són essencials quan l'aprenentatge no supervisat es fa mitjançant xarxes neuronals, com en el cas dels Autoencoders (per a reducció de dimensionalitat complexa) o les GANs (Xarxes Adversàries Generatives).

ELKI: Una plataforma de programari en Java especialitzada específicament en la investigació d'algorismes de clustering i detecció de valors atípics (outliers).

2. Plataformes Empresarials i de NÚVOL (Cloud AI). Ofereixen serveis totalment gestionats de punta a punta, ideals per connectar bases de dades corporatives massives i llançar models a producció sense gestionar servidors.

Amazon SageMaker: La plataforma de AWS compta amb algorismes no supervisats integrats i altament optimitzats per a grans volums de dades, com Random Cut Forest (RCF) per a la detecció d'anomalies en temps real.

Google Vertex AI: Permet executar pipelines complets de clústers i anàlisi exploratòria integrats directament amb el magatzem de dades BigQuery, facilitant la segmentació de clients d'una manera nativa.

Databricks: Aquesta plataforma de dades unificada és excel·lent per a l'aprenentatge no supervisat a gran escala gràcies a la seva integració amb Apache Spark MLlib, gestionant fàcilment clústers paral·lels en milions de registres.

3. Plataformes Visuals i No-Code. Ideals per a analistes que necessiten trobar patrons ocults en les dades sense haver d'escriure línies de codi.

KNIME / Orange AI: Permeten crear fluxos de treball visuals connectant blocs (nodes). Pots arrossegar un fitxer de dades, connectar-lo a un node de K-Means i passar el resultat

directament a un gràfic de dispersió 2D en qüestió de minuts.

H2O.ai: Ofereix capacitats d'aprenentatge automàtic automatitzat (AutoML). El seu sistema analitza les teves dades en brut i tria de forma autònoma quina tècnica no supervisada dona millors resultats mètriques.

5. Fases de l'aprenentatge automàtic no supervisat

Les fases de l'aprenentatge automàtic no supervisat segueixen una estructura similar a la del Machine Learning general, però tenen característiques úniques i molt crítiques en la preparació, entrenament i avaluació, ja que el sistema no disposa d'etiquetes de referència ni de respostes correctes (objectius/targets).

El cicle de vida es divideix en les següents fases clau:

[1. Definició del Repte]

[2. Recollida de Dades]

[4. Extracció i Entrenament]

[5. Validació Mètrica]

[6. Interpretació i Ús]

1. Definició del repte exploratori

A diferència de l'aprenentatge supervisat (on es vol predir un valor concret), aquí es busca descobrir estructures ocultes.

- Definir si l'objectiu és trobar grups de clients (Clustering).
- Definir si es volen trobar anomalies en transaccions bancàries.
- Definir si es requereix simplificar un excés de variables (Reducció de dimensió).

2. Recopilació de dades en brut

Es reuneixen les dades del sistema sense necessitat de passar per un procés d'etiquetatge humà (el qual sol ser car i lent).

- Extreure logs de servidors, historial de compres o dades de sensors.
- Emmagatzemar grans volums de dades estructurades o no estructurades.

3. Preprocessament i Escalat (Fase Crítica)

Com que molts algorismes no supervisats (com K-Means o PCA) es basen en el càlcul de distàncies geomètriques, l'escalat de les dades és obligatori.

- Tractar valors absents o nuls.
- Normalitzar o estandarditzar les variables (perquè una variable amb valors de 0 a 1.000.000 no eclipsi una variable que va de 1 a 10).

4. Selecció, Determinació d'elements i Entrenament

Es tria l'algorisme i es configuren els paràmetres inicials basant-se en l'estructura de

l'espai de dades.

- Aplicar el Mètode del Colze o de la Silueta per determinar el nombre de clústers (K).
- Aplicar el criteri de la Variància Explicada Acumulada per triar el nombre de components en un PCA.
- Executar l'algorisme perquè trobi els patrons, distàncies o regles de forma autònoma.

5. Validació mètrica i geomètrica

Com que no podem comparar els resultats amb una "solució real", s'utilitzen mètriques de cohesió, separació espacial i consistència estadística.

- Mesurar la inèrcia interna dels grups (que siguin compactes).
- Avaluar mètriques com l'índex de Davies-Bouldin o el Coeficient de Silueta.
- Filtrar regles d'associació mitjançant els valors de Support, Confidence i Lift (assegurant que Lift > 1).

6. Interpretació, Desplegament i Monitoratge

L'últim pas requereix la intervenció d'un expert en el negoci per donar sentit als resultats obtinguts per la màquina.

- Posar nom als clústers trobats (Ex: "Clients digitals d'alta despesa").
- Desplegar el model en producció per classificar nous usuaris en temps real o detectar frauds immediatament.
- Monitorar el model, ja que els patrons del món real canvien (canvi de comportament dels consumidors) i caldrà reentrenar el sistema.

6. Aplicació de models de xarxes neuronals

L'aplicació de models de xarxes neuronals (Deep Learning) representa el nivell més avançat del Machine Learning. A diferència dels algorismes clàssics, les xarxes neuronals són capaces d'aprendre representacions de dades complexes gràcies a estructures de capes interconnectades que imiten el comportament del cervell humà.

Seguint el fil del que hem estat analitzant, aquestes xarxes es poden aplicar tant de forma supervisada com no supervisada en molts sectors reals.

6.1. Principals arquitectures i els seus usos reals

Depenent de la naturalesa de les dades (imatges, text, sèries temporals), s'aplica un tipus de xarxa neuronal específic:

Xarxes Neuronals Convolucionals (CNN): Estan especialitzades en processar dades amb estructura de quadrícula, com les imatges.

Aplicació: Diagnòstic mèdic per imatge (detectar tumors en radiografies), conducció

autònoma (reconeixement de senyals de trànsit) i sistemes de seguretat amb reconeixement facial.

Transformers (L'arquitectura d'IA moderna): Han substituït les xarxes recurrents (RNN) gràcies al seu mecanisme d'atenció, capaç de processar seqüències senceres de dades alhora.

Aplicació: Els grans models de llenguatge (LLMs com GPT o Claude), traducció automàtica en temps real, generació de resums de text i assistents virtuals intel·ligents.

Autoencoders (Aprentatge No Supervisat): Xarxes dissenyades per comprimir les dades d'entrada en una dimensió menor i després reconstruir-les.

Aplicació: Com hem vist anteriorment, són vitals per a la reducció de dimensionalitat no lineal, eliminació de soroll en imatges o àudio, i detecció d'anomalies (si la xarxa no pot reconstruir bé una dada, és que és anòmla).

6.2. Com s'apliquen les xarxes neuronals? El flux de treball

Per aplicar una xarxa neuronal amb èxit, es segueix un pipeline molt estricte a les plataformes que hem comentat (com PyTorch o TensorFlow):

[1. Definir Arquitectura] →

[2. Propagació Endavant] →

[3. Calcular Error] →

[4. Retropropagació]

Definició de l'arquitectura: Es tria el nombre de capes ocultes, el nombre de neurones per capa i les funcions d'activació (com ReLU o Sigmoid) que afegeixen no-linealitat al model.

Propagació cap endavant (Forward Propagation): Les dades entren a la xarxa, es multipliquen pels "pesos" d'una capa a l'altra, i es genera una predicció final.

Càlcul de la funció de pèrdua (Loss Function): Es mesura matemàticament la distància o error entre la predicció de la xarxa i el valor real.

Retropropagació (Backpropagation) i Optimització: L'error es llança cap enrere a través de la xarxa utilitzant l'algorisme del gradient descendent. L'optimitzador (com Adam o SGD) ajusta tots els pesos de les neurones per reduir l'error en la següent iteració.

6.3. Reptes en la seva aplicació

- Són una "Caixa Negra": És molt difícil interpretar exactament per què una xarxa neuronal pren una decisió concreta, a diferència de les regles d'associació clàssiques.
- Requisit de dades i potència: Demanen milers o milions de registres per ser eficients i requereixen de targetes gràfiques potents (GPUs) per al seu entrenament.

7. Com aprèn una xarxa neuronal

Una xarxa neuronal està formada per tres tipus de capes:

Capa d'entrada (Input Layer) Rep les dades inicials.

Exemple:

Una imatge formada per milers de píxels.

Capes ocultes (Hidden Layers) Processen la informació mitjançant operacions matemàtiques.

Cada capa aprèn unes característiques més complexes que l'anterior.

Capa d'eixida (Output Layer) Produeix el resultat final.

Exemple:

"Gos", "Gat" o "Cotxe".

Una xarxa neuronal aprèn mitjançant un procés iteratiu de correcció d'errors. A grans trets, el sistema fa una predicció, calcula quant s'ha equivocat i ajusta els seus paràmetres interns perquè la pròxima vegada l'error siga menor.

Aquest mecanisme es basa en tres pilars matemàtics que es repeteixen milions de vegades durant l'entrenament:

7.1. Els components ajustables:

Pesos i Biaixos Cada neurona està connectada amb les de la capa següent. Aquestes connexions tenen dos elements clau: Els pesos (Weights): Són valors numèrics que determinen la importància que se li dona a una informació concreta. Si una dada és clau per resoldre el problema, el seu pes augmentarà. Els biaixos (Biases): Són valors que s'activen per desplaçar el resultat de la neurona cap amunt o cap avall, permetent que el model s'ajusti millor a patrons complexos.

7.2. El cicle d'aprenentatge en 3 passos.

Aquest cicle es coneix com el bucle d'entrenament i funciona de la següent manera:

[Pas 1: Propagació cap endavant] →

[Pas 2: Funció de Pèrdua] →

[Pas 3: Retropropagació]

Pas 1: Propagació cap endavant (Forward Propagation) Les dades d'entrada (per exemple, els píxels d'una foto d'un gat) entren a la xarxa. La informació viatja de capa en capa, multiplicant-se pels pesos i sumant-se als biaixos. Al final, la xarxa dona un resultat (Ex: "Estic un 60% segur que és un gos").

Pas 2: El càlcul de l'error (Loss Function) Com que estem entrenant el sistema, sabem que la foto realment era un gat. La funció de pèrdua calcula matemàticament la distància entre el que ha dit la xarxa (gos) i la realitat (gat). Com més gran és la distància, més alta és la "pèrdua" o càstig del model.

Pas 3: Retropropagació (Backpropagation) Aquest és el cervell de l'aprenentatge. L'error calculat es llança cap enrere a través de la xarxa, des de la sortida fins a l'entrada. Utilitzant el càlcul de derivades (gradients), l'algorisme esbrina quines neurones i quins pesos concrets han estat els responsables de l'error.

3. L'optimitzador i el Gradient Descent

Una vegada la xarxa sap quins pesos ha de canviar, utilitza un algorisme anomenat Gradient Descent (Gradient Descent).


Imagina que la xarxa està al pic d'una muntanya boirosa (màxim error) i vol baixar a la vall (mínim error). A cada pas de la retropropagació, la xarxa fa un petit pas avall en la direcció de la pendent més pronunciada. Taxa d'aprenentatge (Learning Rate): És la mida d'aquest pas. Si el pas és massa gran, la xarxa pot saltar-se la vall i fallar. Si és molt menuda tardarà molt en aprendre.

L'OPTIMITZADOR I EL GRADIENT DESCENDENT

En l'aprenentatge automàtic, entrenem un model ajustant els seus paràmetres per minimitzar una funció de pèrdua.


1. L'OBJECTIU: MINIMITZAR LA PÈRDUA

El model té uns paràmetres θ (pesos i biaixos). La funció de pèrdua $J(\theta)$ mesura quant d'error comet el model. L'objectiu és trobar els valors de θ que fan mínima $J(\theta)$.

$$\theta^* = \arg \min_{\theta} J(\theta)$$


2. EL GRADIENT

El gradient $\nabla J(\theta)$ és un vector que apunta en la direcció de màxim creixement de la funció. Per tant, $-\nabla J(\theta)$ apunta cap avall, cap a la direcció de descens més fort.




3. GRADIENT DESCENDENT

És un algorisme iteratiu que actualitza els paràmetres en la direcció oposada al gradient per reduir la pèrdua.

$$\theta_{t+1} = \theta_t - \eta \nabla J(\theta_t)$$


on η (eta) és la taxa d'aprenentatge (learning rate).

- Si η és massa gran: podem saltar el mínim o divergir.
- Si η és massa xicoteta: convergim molt a poc a poc.
- Cal triar η adequadament.



4. COM FUNCIONA (INTUÏTIVAMENT)


- Iniciem amb uns paràmetres aleatoris θ_0 .
- Calculem el gradient $\nabla J(\theta_t)$.
- Ens movem un poc cap a $-\nabla J(\theta_t)$.
- Repetim fins que la pèrdua siga suficientment xicoteta o no millora més.



5. EXEMPLE 1D (FUNCIO QUADRÀTICA)

$$J(\theta) = (\theta - 3)^2$$

El mínim és en $\theta = 3$. El gradient és:

$$\frac{dJ}{d\theta} = 2(\theta - 3)$$


6. OPTIMITZADORS MÉS COMUNS

Optimitzador	Idea principal	Avantatges	Inconvenients
Gradient Descent (GD)	Actualitza amb el gradient	Simple, fàcil d'implementar	Pot ser lent, sensible a η
Momentum	Afig "inèrcia" a les actualitzacions	Redueix oscil·lacions, més ràpid	Cal triar hiperparàmetres
RMSProp	Ajusta η per paràmetre amb mitjana mòbil del gradient ²	Funciona bé en problemes no convexos	Pot disminuir massa η
Adam	Combina Momentum i RMSProp	Robust, ràpid, molt utilitzat	Pot generalitzar pitjor en alguns casos

 **EN RESUM:** L'optimitzador (com el Gradient Descent) és el motor que ajusta els paràmetres del model per minimitzar la pèrdua i millorar l'aprenentatge.

8. Xarxes neuronals artificials

Artificial Neural Networks (ANN) són models computacionals inspirats en la lliçó biològica del sistema nerviós humà. Estan formades per unitats de processament (neurones artificials) organitzades en capes (capa d'entrada, capes ocultes i capa d'eixida) que es connecten entre elles per transmetre i transformar la informació.

Depenent de la manera com es connecten aquestes neurones i de la finalitat del model, es classifiquen en diferents tipus d'arquitectures:

8.1 Xarxes Neuronals de Propagació cap Endavant (Feedforward / MLP)

Són el model més clàssic, senzill i la base del Deep Learning.

Estructura: La informació es mou en una sola direcció: des de la capa d'entrada, passant per les capes ocultes (Perceptró Multicapa o MLP), fins a la capa d'eixida. No hi ha cicles ni bucles cap enrere.

Aplicació típica: Classificació de dades tabulars directes (ex: predir si un client bancari demanarà un crèdit segons la seva edat i ingressos).

8.2 Xarxes Neuronals Convolucionals (CNN)

Dissenyades específicament per processar dades amb una estructura espacial o de graella, com les imatges o els mapes 2D.

Estructura: Utilitzen operacions matemàtiques de convolució mitjançant "filtres" que llisquen sobre la imatge. Això permet al model extreure patrons visuals simples (vores, textures) a les primeres capes, i formes complexes (ulls, rodes, objectes sencers) a les capes profundes.

Aplicació típica: Visió per ordinador, reconeixement facial, diagnòstic de radiografies i conducció autònoma.

8.3 Xarxes Neuronals Recurrents (RNN / LSTM)

Creades per treballar amb dades seqüencials o sèries temporals, on l'ordre dels elements és fonamental.

Estructura: A diferència de les Feedforward, tenen connexions cícliques (bucles) que funcionen com una memòria interna. Permeten que la informació del passat influeixi en la predicció del present. Les variants LSTM (Long Short-Term Memory) solucionen el problema de l'oblit a llarg termini.

Aplicació típica: Anàlisi de text (NLP), traducció de text paraula per paraula i predicció de valors de borsa o del clima.

8.4 Transformers (L'estàndard actual)

L'arquitectura moderna que ha revolucionat el processament del llenguatge natural i ha superat les RNN tradicionals.

Estructura: Substitueixen l'anàlisi seqüencial per un mecanisme anomenat Atenció (Self-Attention). Això els permet processar frases senceres (o blocs de dades massives) de cop, entenent el context global de cada paraula sense importar com estiguin de separades dins d'un text.

Aplicació típica: Grans models de llenguatge (LLMs com el nucli de GPT, Claude), generadors de codi i anàlisi genòmica complexa.

8.5 Autoencoders (Aprentatge No Supervisat)

Models simètrics dissenyades per fer auto-comprensió de dades sense etiquetes.

Estructura: Consten d'un Encoder (comprimeix la informació d'entrada cap a un espai central molt reduït anomenat coll d'ampolla) i un Decoder (intenta reconstruir la dada

original a partir d'aquella compressió).

Aplicació típica: Reducció de dimensionalitat no lineal, eliminació de soroll d'àudio/imatge i detecció d'anomalies en sistemes industrials.

Tema 5. Valoració dels resultats obtinguts amb aprenentatge automàtic



1. Capacitat de generalització
2. Test
3. Validació
4. Matriu de confusió

Quan un model de Machine Learning ha estat entrenat, cal comprovar si realment funciona bé. Per això, se n'avalua el rendiment utilitzant diferents mètodes i mètriques que permeten conèixer si el model és capaç de fer prediccions correctes sobre dades noves.

Un bon model no ha de limitar-se a memoritzar les dades amb què ha estat entrenat, sinó que ha de ser capaç de generalitzar, és a dir, aplicar allò après a situacions noves.

1. Capacitat de generalització

Què és la generalització? La capacitat de generalització és l'habilitat que té un model per fer prediccions correctes sobre dades que mai no ha vist durant l'entrenament.

És un dels aspectes més importants de l'aprenentatge automàtic, ja que l'objectiu d'un model és funcionar correctament en situacions reals.

Exemple. Suposem un model entrenat per reconèixer gats i gossos.

Si identifiqueu correctament les imatges noves, generalitzeu bé.

Si només reconeix les imatges utilitzades durant l'entrenament i falla amb altres de noves, no generalitza correctament.

Importància de la generalització Un model amb bona capacitat de generalització:

- Ofereix prediccions fiables.
- És útil en aplicacions reals.
- Redueix la probabilitat de cometre errors.

Problemes relacionats amb la generalització Sobreajustament (Overfitting) El sobreajustament passa quan el model aprèn massa bé les dades d'entrenament, incloent-hi els errors o les particularitats.

Com a conseqüència:

- Obté resultats excel·lents durant l'entrenament.
- Presenta mals resultats amb dades noves.

Exemple: un estudiant que memoritza les respostes d'un examen, però no comprèn la matèria i falla quan canvien les preguntes.

Infraajustament (Underfitting) L'infraajustament passa quan el model és massa simple i no aconsegueix aprendre correctament els patrons presents a les dades.

Com a conseqüència:

Comet molts errors tant en entrenament com en proves.

Exemple: un estudiant que estudia molt poc i no respon correctament ni preguntes conegudes ni noves.

Com millorar la generalització

Per millorar la capacitat de generalització es poden aplicar diverses tècniques:


- Utilitzar un conjunt de dades ampli i representatiu.
- Eliminar errors i dades incorrectes.
- Evitar models excessivament complexos.
- Aplicar tècniques de regularització.
- Ajustar correctament els hiperparàmetres.
- Utilitzar validació creuada.

2. Test

El test (testing) és la fase definitiva per mesurar el rendiment real d'un model de Machine Learning. El seu objectiu és simular com funcionarà l'algorisme al món real en enfrontar-se a dades completament noves que mai ha vist durant la fase d'entrenament, evitant així el parany del sobreajustament (overfitting).

2.1 El principi de la divisió de dades

Abans de començar qualsevol projecte, el conjunt de dades original es divideix de forma estricta en blocs separats. La proporció de test més habitual és la següent:



Regla d'or: Les dades de test han d'estar tancades amb clau. No es poden utilitzar mai per entrenar el model ni per prendre decisions sobre quins paràmetres tocar. Són exclusivament per a l'examen final.

2.2 Mètodes de test i validació

- **Hold-Out Tradicional:** És la divisió directa (com l'esquema superior). És ràpid, però si el conjunt de dades és xicotet, el resultat del test pot dependre molt de la sort en com s'han repartit les dades.
- **Validació Encreuada (K-Fold Cross-Validation):** Es divideixen les dades en K parts. El model s'entrena K vegades, utilitzant cada vegada una part diferent com a test i la resta com a entrenament. El resultat final és la mitjana de tots els tests, cosa que dona una valoració molt més robusta i estable.

2.3 Les mètriques de valoració segons el tipus de model

Un cop passem el test, la forma d'avaluar l'error canvia radicalment depenent del problema:

A. En problemes de Classificació (Predir etiquetes, ex: "Frau" o "No Frau")

S'utilitza la Matriu de Confusió per creuar les prediccions del test amb la realitat, extreient-ne quatre mètriques clau:

- **Exactitud (Accuracy):** Percentatge total de prediccions correctes. Pot ser enganyós si les classes estan molt desequilibrades.
- **Precisió (Precision):** De tot el que el model ha dit que és positiu, quant ho és realment. (Crucial per evitar falsos positius, com bloquejar comptes bancaris legítims).
- **Sensibilitat (Recall):** De tot el que era positiu en la realitat, quant ha estat capaç de detectar el model. (Crucial per evitar falsos negatius, com deixar passar un càncer en una radiografia).
- **F1-Score:** La mitjana harmònica entre Precisió i Sensibilitat. És el millor indicador general.

B. En problemes de Regressió (Predir valors numèrics, ex: "Preu d'una casa")

- **MAE (Error Absolut Mitjà):** La mitjana de les diferències en valor absolut. És fàcil d'interpretar (ex: "el model s'equivoca de mitjana en 5 €").
- **RMSE (Arrel de l'Error Quadràtic Mitjà):** Penalitza de forma molt més severa els errors grans. Si el model s'equivoca molt en una sola predicció, el RMSE es dispararà.
- **R^2 (Coeficient de determinació):** Indica quanta proporció de la variabilitat de les dades és capaç d'explicar el model (va de 0 a 1).

3. Validació

La validació de models de machine learning és el procés clau per garantir que un model generalitza correctament davant de dades noves i evitar problemes com el sobreajustament (overfitting) o el subajustament (underfitting).

Aquest procés avalua la precisió, fiabilitat i robustesa de l'algorisme abans de posar-lo en producció.

3.1 Mètodes de divisió de dades

Dividir correctament el conjunt de dades original és el primer pas imprescindible per fer una validació rigorosa.

- Train / Test Split: Divideix les dades en entrenament (p. ex., 80%) i prova (20%).
- Train / Validation / Test Split: El conjunt de validació serveix per ajustar hiperparàmetres; el de test és exclusiu per a l'avaluació final.
- Validació en sèries temporals: Manté l'ordre cronològic de les dades per evitar filtracions del futur al passat.

3.2 Tècniques avançades de validació

- Quan les dades són limitades o es busca una validació més robusta, s'utilitzen estratègies iteratives.
- Validació creuada de K iteracions (K-Fold): Divideix les dades en K parts iguals; entrena el model K vegades fent servir una part diferent com a validació cada cop.
- K-Fold estratificat: Manté la proporció de classes de la variable objectiu a cada partició, ideal per a dades desbalancejades.

3.3 Mètriques d'avaluació segons el tipus de model

L'èxit de la validació depèn de triar la mètrica correcta per al problema.

Models de Classificació (Variables categòriques)

- Matriu de confusió: Taula creuada que mostra els encerts i errors (falsos positius i falsos negatius).
- Precisió (Precision): Proporció de prediccions positives que realment són correctes.
- Sensibilitat (Recall / Sensitivity): Proporció de casos positius reals que el model ha estat capaç d'identificar.
- F1-Score: Mitjana harmònica entre la precisió i la sensibilitat.
- Corba ROC i AUC: Mesura la capacitat del model per separar les diferents classes.

Models de Regressió (Variables numèriques contínues)

- MAE (Error absolut mitjà): Mitjana de les diferències absolutes entre els valors reals i els predits.
- MSE (Error quadràtic mitjà): Mitjana dels errors al quadrat; penalitza amb més força els errors grans.
- RMSE (Arrel de l'error quadràtic mitjà): Manté la mateixa unitat de mesura que la variable original.
- R^2 (Coeficient de determinació): Indica quin percentatge de la variabilitat de les dades explica el model.

3.4 Validació més enllà del rendiment mètric

Un model amb bones mètriques encara pot fallar en el món real si no es validen aspectes estructurals i ètics.

- Anàlisi de biaix i equitat: Comprova si el model discrimina o penalitza certs col·lectius de manera injusta.
- Interpretabilitat: Ús d'eines com valors SHAP o gràfics PDP per entendre quines característiques influeixen més en les decisions.
- Data Drift (Desviació de dades): Monitoratge continu post-implementació per detectar si les dades reals canvien respecte a les dades d'entrenament.

4. Matriu de confusió

La matriu de confusió és una eina fonamental per avaluar el rendiment d'un model de classificació en Machine Learning. És una taula de doble entrada que creua els valors reals de les dades amb les prediccions fetes pel model, permetent veure exactament on encerta i on s'equivoca. Estructura de la matriu de confusió (Classificació Binària) En un problema amb dues classes (Positiu / Negatiu), la matriu té una mida de 2x2 i genera quatre quadrants clau:

	Predicció: NEGATIU	Predicció: POSITIU
Realitat: NEGATIU	Vertader Negatiu (VN) El model diu NO i és NO.	Fals Positiu (FP) El model diu SÍ, però és NO. (<i>Error Tipus I</i>)
Realitat: POSITIU	Fals Negatiu (FN) El model diu NO, però és SÍ. (<i>Error Tipus II</i>)	Vertader Positiu (VP) El model diu SÍ i és SÍ.

Exemple pràctic: Detecció de correus brossa (Spam)

Imagina que tenim un filtre que avalua 100 correus electrònics:

Vertaders Positius (VP) = 15: 15 correus eren spam i el model els va detectar correctament.

Vertaders Negatius (VN) = 75: 75 correus eren legítims i el model els va deixar passar.

Falsos Positius (FP) = 7: 7 correus legítims es van marcar erròniament com a spam (aniran a la brossa per error).

Falsos Negatius (FN) = 3: 3 correus que eren spam van arribar a la bústia d'entrada principal.

Mètriques derivades de la matriu

A partir d'aquests quatre valors, es calculen les mètriques clau per validar el model sense dependre només de l'exactitud global:

- Exactitud (Accuracy): Proporció total de prediccions correctes.

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN} = \frac{15 + 75}{100} = 90\%$$

- Precisió (Precision): De tot el que el model diu que és positiu, quant en sap realment? (Evita falsos positius).

$$\text{Precision} = \frac{VP}{VP + FP} = \frac{15}{15 + 7} = 68.1\%$$

- Sensibilitat (Recall / Sensitivity): De tots els casos positius reals que existien, quants ha estat capaç de capturar el model? (Evita falsos negatius).

$$\text{Recall} = \frac{VP}{VP + FN} = \frac{15}{15 + 3} = 83.3\%$$

- F1-Score: L'equilibri perfecte entre precisió i sensibilitat, ideal per a conjunts de dades desequilibrats.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = 74.9\%$$

Per què és millor que mirar només l'exactitud?

Si tens un model mèdic per detectar una malaltia rara que només té 1 de cada 100 persones, un model que diga sempre "sa" tindrà un 99% d'exactitud. Tanmateix, la matriu de confusió mostraria immediatament que els Falsos Negatius són del 100% per a la classe malalta, revelant que el model és completament inútil per al seu propòsit.